

	PAGE DE GARDE DES RAPPORTS DE STAGE		Date du stage du 03/03/2025 au 03/09/2025
	Stage d'exécution ☐ Stage élève – ingénieur ☐		
	Stage année de césure : 12 mois ☐ 1er semestre ☐ 2ème semestre ☐		
	Stage projet de fin d'études ☒		

NOM et PRENOM du stagiaire: JUMELLE Capucine

Spécialité: ☐ CGP ☒ ETI

CONFIDENTIALITE du RAPPORT: ☐ OUI ☒ NON

Développement d'un modèle pronostique de l'éveil chez des patients comateux par analyse d'images multimodales IRM et TEP

Development of a Prognostic Model for Awakening in Comatose Patients Using Multimodal MRI and PET Image Analysis



Nom de l'entreprise /organisme: CERMEP

Ville: Bron

Pays: France

Nom et Prénom du maître de stage: COSTES Nicolas

Fonction: Ingénieur de recherche sur la plateforme IRM-TEP au CERMEP

Nom de l'entreprise /organisme: CREATIS

Ville: Villeurbanne

Pays: France

Nom et Prénom du maître de stage: LARTIZIEN Carole

Fonction: Directrice de recherche à CREATIS

SOMMAIRE

1. REMERCIEMENTS.....	3
2. GLOSSAIRE.....	4
3. INTRODUCTION.....	6
4. BIBLIOGRAPHIE.....	6
5. OBJECTIFS DU STAGE.....	8
6. DONNÉES.....	9
6.1. Protocole d'acquisition et prétraitement des images.....	10
6.1.1. IRM anatomique.....	10
6.1.2. IRM de perfusion.....	10
6.1.3. IRM de diffusion.....	10
6.1.4. TEP - ImgCMRGlu.....	11
6.2. Segmentation des structures cérébrales régionales et des lésions.....	11
6.2.1. Parcellisation regionales.....	11
6.2.2. Segmentation lésionnelle.....	11
7. MÉTHODES.....	12
7.1. Prétraitement des données.....	12
7.1.1. IRM T1 et T2 FLAIR - Segmentation lésionnelle.....	12
7.1.2. TEP au FDG et IRM de perfusion.....	13
7.1.3. IRM de diffusion.....	14
7.1.4. Carte de parcellisation.....	16
7.1.4.1. Parcellisation Hammers.....	16
7.1.4.2. Parcellisation macroscopique CRF.....	16
7.2. Extraction des caractéristiques.....	17
7.2.1. Segmentation lésionnelle (IRM T1 et T2 FLAIR).....	17
7.2.2. TEP au FDG et IRM de perfusion.....	18
7.2.3. IRM de diffusion.....	19
7.2.4. Données manquantes.....	20
7.3. Analyse statistiques et visualisation des données.....	20
7.4. Modèles de classification par apprentissage automatique.....	21
7.4.1. Modèles de classification supervisée.....	21
7.4.2. Plan d'expérience.....	21
7.4.3. Métriques d'évaluation.....	23
7.4.4. Evaluation des performances.....	23
8. RÉSULTATS.....	24
8.1. Prétraitement des données.....	24
8.1.1. IRM T1 et T2 FLAIR - Segmentation lésionnelle.....	24
8.1.2. TEP au FDG et IRM de perfusion.....	25
8.1.3. IRM de diffusion.....	25
8.1.4. Carte de parcellisation.....	25
8.1.4.1. Parcellisation Hammers.....	25
8.1.4.2. Parcellisation macroscopique CRF.....	26
8.2. Extraction des caractéristiques.....	26

8.2.1. Segmentation lésionnelle (IRM T1 et T2 FLAIR).....	26
8.2.2. TEP au FDG et IRM de perfusion.....	28
8.2.3. IRM de diffusion.....	29
8.2.4. Données manquantes.....	30
8.3. Analyse statistiques et visualisation des données.....	30
8.4. Modèles de classification par apprentissage automatique.....	32
8.4.1. Plan d'expérience.....	32
8.4.2. Evaluation des performances.....	33
9. DISCUSSION.....	35
10. CONCLUSION.....	36
11. RÉFÉRENCES.....	38
12. ANNEXES.....	40
13. RÉSUMÉ.....	54

1. REMERCIEMENTS

Je tiens à exprimer ma profonde gratitude à [Nicolas Costes](#) et [Carole Lartizien](#), mes deux maîtres de stage, pour leur accompagnement tout au long de ces mois. Merci de m'avoir guidée avec bienveillance, d'avoir partagé vos connaissances et de m'avoir permis d'approfondir mes compétences en imagerie médicale et en apprentissage automatique. Votre encadrement m'a également permis de participer à de nombreuses réunions d'équipe, ce qui m'a aidée à apprendre à présenter mon travail à des interlocuteurs variés : des médecins des HCL aux doctorants et post-doctorants de CREATIS. Merci de m'avoir encouragée à toujours aller plus loin dans mes réflexions et dans la résolution de problèmes.

Je remercie également tout particulièrement [Inès Mérida](#), pour le temps qu'elle m'a consacré au début de mon stage afin de me présenter les travaux antérieurs, m'installer dans mon environnement de travail et m'expliquer les outils à ma disposition. Merci aussi pour ta disponibilité et tes conseils tout au long de mon stage, pendant ton congé maternité.

Je souhaite également remercier [Éric Van Reeth](#) et [Nicolas Duchateau](#), mes référents respectifs à CPE Lyon et Polytech Lyon, pour le suivi de mon stage. Merci d'avoir pris le temps de vous assurer que tout se déroulait bien et pour vos remarques constructives lors du point à mi-parcours, qui m'ont aidée à prendre du recul sur mon travail.

Enfin, je remercie du fond du cœur mes parents, pour leur soutien indéfectible, tant sur le plan financier que moral, pendant ce stage de fin d'études et tout au long de mon parcours académique. Ce stage marque la fin d'un long chemin, que je n'aurais sûrement pas pu accomplir sans leur appui constant.

2. GLOSSAIRE

AD	Axial Diffusivity (Diffusion axiale)
ASL	Arterial Spin Labeling
AUC	Area Under the Curve
AVC	Accident Vasculaire Cérébral
CBF	Cerebral Blood Flow (débit sanguin cérébral)
CERMEP	Centre d'Etude et de Recherche Multimodal et Pluridisciplinaire en Imagerie du vivant
CL	Charge lésionnelle
CMRGlu	Cerebral Metabolic Rate of Glucose (Consommation métabolique cérébral du glucose)
Cp	Concentration plasmatique
CRF	Case Report Form. Carte de parcellisation <i>CRF</i> (56 régions macroscopiques): basé sur les désignations anatomiques cérébrales définie dans le CRF de l'étude de recherche clinique IMAGINA
DWI	Diffusion Weighted Imaging (imagerie pondérée en diffusion)
EEG	Électroencéphalogramme
ETI	Électronique, Télécommunications et Informatique
ETIC	Essai clinique promu par les HCL mené au Service de réanimation de l'Hôpital neurologique Pierre Wertheimer par le Dr Florent Gobert. Le projet vise à étudier, par imagerie multimodale, les des états de conscience altérée
FA	Fractional Anisotropy (fraction d'anisotropie calculée à partir d'une IRM de diffusion)
FDG	Fluorodésoxyglucose
FLAIR	Fluid Attenuated Inversion Recovery (séquence IRM de mesure d'atténuation des fluides par inversion-récupération)
HCL	Hospices Civils de Lyon
IA	Intelligence Artificielle
IMAGINA	Projet de recherche financé par l'Agence nationale pour la recherche. Nom également du second essai clinique promu par les HCL, mené à l'Hôpital neurologique Pierre Wertheimer visant à étudier, par imagerie multimodale, les états de conscience altérée
IRM	Imagerie par Résonance Magnétique
IRMf	IRM fonctionnelle

LCR	Liquide Céphalo-Rachidien (= CSF, Cerebro-spinal fluid)
MD	Mean Diffusivity (Diffusion moyenne)
NA	Not Available / Non Applicable
RD	Radial Diffusivity (Diffusion radiale)
SUV	Standardized Uptake Value. Mesure d'activité TEP normalisée par le poids du sujet et la dose injectée
SVM	Support Vector Machine (Machine à vecteurs de support)
T1	Séquence d'IRM pondérée en T1
T2	Séquence d'IRM pondérée en T2
TDC	Troubles de la Conscience
TEP	Tomographie par Émission de Positons
TI	Temps d'inversion
WMGM	White Matter - Grey Matter (matière blanche / grise)

3. INTRODUCTION

Ce rapport scientifique a été réalisé dans le cadre du stage de fin d'études du parcours Ingénieur en Électronique, Télécommunications et Informatique, spécialité Image, Modélisation et Informatique de CPE Lyon.

Ce stage s'inscrit dans le cadre du projet de recherche ANR IMAGINA (Imagerie translationnelle et multimodale des corrélats neuronaux de la vigilance et de la conscience)[1], et vise à développer des outils d'intelligence artificielle pour prédire l'état de conscience de patients comateux à partir d'imagerie multimodale acquise simultanément par Imagerie par Résonance Magnétique (IRM) et (Tomographie par Émission de Positons) TEP. Il est encadré au sein d'un consortium interdisciplinaire réunissant notamment le CERMEP, plateforme d'imagerie du vivant dédiée à la recherche et dotée d'une caméra hybride IRM-TEP, et CREATIS, laboratoire de recherche lyonnais spécialisé dans le traitement et l'analyse d'images biomédicales. Le CERMEP joue un rôle central dans la collecte et le prétraitement des données cliniques, tandis que CREATIS développe les méthodes d'analyse fondées sur l'IA. Le stage consiste à exploiter les données issues d'une cohorte résultant des études ETIC et IMAGINA (71 patients) pour extraire des biomarqueurs régionaux à partir des cartes paramétriques IRM et TEP, puis à concevoir et évaluer un modèle d'apprentissage statistique permettant d'établir un pronostic automatisé de l'éveil chez ces patients.

4. BIBLIOGRAPHIE

Les troubles de la conscience (TDC) représentent un large spectre de conditions caractérisées par une altération de la conscience de soi et de l'environnement, pouvant survenir à la suite de diverses atteintes cérébrales. Parmi les causes fréquentes figurent les traumatismes crâniens, les hémorragies cérébrales et les arrêts cardiaques, ainsi que des étiologies vasculaires, métaboliques, infectieuses, tumorales ou toxiques. Les TDC (**figure 1**) incluent notamment le coma, l'état végétatif (également appelé syndrome d'éveil non répondant) et l'état de conscience minimale. Bien que chacun de ces états présente des caractéristiques cliniques distinctes, leur diagnostic précis et leur évaluation demeurent des défis majeurs, malgré les progrès récents en neurosciences et en médecine de soins intensifs.




Figure 1: Différents étapes de la conscience altérée

Traditionnellement, l'évaluation des patients atteints de TDC repose sur l'analyse du comportement, intrinsèquement liée à leur capacité à produire des réponses observables (mouvement volontaire, réponse verbale). Cela implique des taux de diagnostics erronés qui peuvent atteindre 40%, ce qui induit des répercussions majeures sur la prise en charge des patients [2].

Les techniques d'imagerie cérébrale permettent de caractériser avec plus de précisions ces états. Cependant, bien que précieuses, elles présentent des limites lorsqu'elles sont utilisées isolément. L'IRM anatomique permet d'évaluer l'étendue des lésions, mais donne peu d'informations fonctionnelles, tandis que l'IRM fonctionnelle (IRMf) est sensible aux mouvements. La TEP au $[^{18}\text{F}]\text{FDG}$ offre une information sur

l'activité métabolique cérébrale, mais avec une résolution spatiale limitée et une spécificité peu discriminante. Aucune de ces modalités ne fournit à elle seule une image suffisamment informative de l'état fonctionnel du cerveau permettant d'identifier l'état de conscience [3]. Pour pallier ces limites, les approches multimodales combinent plusieurs techniques complémentaires, offrant ainsi une évaluation plus précise des fonctions cérébrales résiduelles [4][5]. Cette complémentarité a permis d'identifier des signes de conscience chez 15 à 20 % des patients pourtant considérés comme non conscients selon les évaluations comportementales classiques [4].

Par ailleurs, l'évaluation multimodale contribue au pronostic de l'état de conscience. L'étude multicentrique menée par Puybasset et al. a développé un score pronostique basé sur des métriques tirées d'images d'IRM de diffusion (fractional anisotropy et mean diffusivity) mesurées dans la substance blanche profonde entre le 7^e et le 35^e jour après un traumatisme crânien. Cette approche a permis de prédire l'issue clinique à un an (favorable ou défavorable selon le score Glasgow) avec une spécificité supérieure à 95 % pour les deux issues. Le modèle a été validé sur une large cohorte externe combinant les données des études MRI-COMA et CENTER-TBI, représentant un exemple de prédiction de l'éveil à long terme basée sur une modalité unique, mais intégrée dans une stratégie de prise en charge multimodale [6].

L'analyse radiomique, en extrayant de nombreuses caractéristiques quantitatives à partir de ces images, devient un outil précieux pour le diagnostic et le pronostic. Elle permet notamment de mieux caractériser les lésions cérébrales, d'identifier des biomarqueurs, et de prédire l'évolution des pathologies. Les caractéristiques extraites incluent des mesures morphologiques (forme, volume), d'intensité (distribution des voxels), texturales (hétérogénéité des tissus), fonctionnelles (activité cérébrale) et moléculaires (processus biochimiques *via* la TEP)[7].

Le projet de ce stage repose sur l'utilisation combinée de plusieurs modalités d'imagerie cérébrale, chacune apportant des informations complémentaires sur la structure, la perfusion, la connectivité et le métabolisme cérébral.

Tout d'abord, l'IRM fournit une imagerie haute résolution des tissus mous. Elle repose sur la mesure de l'énergie libérée au retour à l'équilibre après excitation par une onde radiofréquence des protons dont les spins sont alignés grâce à un champ magnétique intense ($>0.5T$). L'imagerie anatomique s'appuie sur des séquences IRM pondérées en T1 (T1-weighted, T1w) et FLAIR (Fluid-Attenuated Inversion Recovery). Les images T1w (**figure 2a**) offrent une résolution élevée et un bon contraste entre la substance grise, la substance blanche et le liquide céphalorachidien (LCR), ce qui les rend adaptées aux analyses morphométriques et à l'alignement inter-sujets. Les images FLAIR, basées sur une pondération T2 avec un temps d'inversion spécifique, suppriment le signal du LCR, permettant une meilleure détection des lésions cérébrales hyperintenses, notamment en région périventriculaire.




Figure 2a: IRM T1




Figure 2b: IRM de perfusion - ASL

Ensuite, l'imagerie de perfusion est réalisée par ASL (Arterial Spin Labeling), une technique d'IRM non invasive qui permet de mesurer le flux sanguin cérébral (CBF, cerebral blood flow) sans injection de produit de contraste (**figure 2b**). Elle repose sur le marquage magnétique du sang artériel en amont à l'aide d'impulsions radiofréquences répétées, couplées à un champ de gradient simulant un flux sanguin continu. Ce marquage entraîne une inversion progressive de l'aimantation des spins

dans une région extracrânienne ; le sang ainsi étiqueté migre naturellement vers les tissus cérébraux, où une image est acquise après un délai post-étiquetage (PLD, Post-Labeling Delay). La différence entre l'image étiquetée et une image contrôle reflète la perfusion locale et permet de générer une image pondérée par le flux sanguin, dont le signal est normalisé à l'aide d'une image de calibration (M_0). Cette méthode fournit une estimation quantitative du CBF (en mL/100g/min) dans les cas d'AVC, de tumeurs ou de maladies neurodégénératives.

De plus, l'IRM de diffusion (DWI) permet d'évaluer la microstructure cérébrale en mesurant la diffusion des molécules d'eau dans les tissus (**figure 2c**). Elle est particulièrement utile pour détecter les zones de diffusion restreinte, caractéristiques des accidents vasculaires ischémiques précoces, de certaines tumeurs ou des lésions de la substance blanche. L'analyse des données de diffusion permet d'estimer l'intégrité des fibres de matière blanche, notamment grâce à l'anisotropie de la diffusion observée dans ces régions, où l'organisation des fibres nerveuses contraint le mouvement de l'eau selon des directions privilégiées.




Figure 2c: IRM de diffusion




Figure 2d: TEP CMRGlu

Enfin, la TEP est utilisée pour mesurer le métabolisme glucidique cérébral au repos à l'aide du $[^{18}\text{F}]\text{FDG}$ (**figure 2d**). Le FDG, analogue du glucose marqué au fluor-18, est capté et phosphorylé par les cellules mais reste piégé: cela permet de réaliser une mesure proportionnelle à l'activité métabolique que l'on peut quantifier. Les photons gamma émis suite à l'annihilation du positon émis par le fluor 18 avec un électron, sont détectés en coïncidence pour reconstruire une image 3D.

5. OBJECTIFS DU STAGE

Ce stage vise à explorer l'efficacité de l'approche multimodale pour prédire l'éveil chez les patients comateux en phase aiguë, en s'appuyant sur le développement d'un modèle d'apprentissage automatique pour l'analyse des données. Pour cela, un travail méthodique est nécessaire: il comprend le prétraitement des différentes modalités d'imagerie, l'extraction des caractéristiques les plus pertinentes pour chaque type d'examen, puis la conception d'un algorithme capable d'anticiper l'évolution clinique du patient. L'objectif final est de prédire l'état de conscience au troisième mois post-coma, en se basant sur les données recueillies à l'arrêt des sédations, et en connaissance de l'état du patient trois mois après l'arrêt de la sédation. La vérité terrain est ici définie par une évaluation clinique indiquant si le patient a retrouvé un état d'éveil ou non à cette échéance.

L'un des principaux défis du pronostic chez les patients en état de conscience altérée réside dans l'absence de lien direct et systématique entre l'état d'éveil et les données anatomiques observées à l'IRM. Comme illustré dans la **figure 3**, il est possible qu'un patient présentant d'importantes lésions cérébrales puisse évoluer favorablement et retrouver un état d'éveil après plusieurs mois, tandis qu'un autre patient, avec des lésions minimales, peut ne jamais se réveiller. Cette variabilité souligne la complexité du pronostic et justifie la nécessité de méthodes intégratives et robustes pour mieux comprendre les facteurs sous-jacents à l'évolution clinique.




Figure 3: Illustration de la difficulté du pronostic basé sur l'IRM T1 :

6. DONNÉES

Ce projet repose sur les données issues de deux études cliniques multicentriques, ETIC et IMAGINA, totalisant 71 patients admis en état de coma. Il s'inscrit dans la continuité de plusieurs années de recherche initiées en 2018. Les données comprennent des examens d'imagerie multimodale (IRM et TEP), des scores cliniques à l'admission et 3 mois après l'arrêt de sédation, ainsi que des cartes lésionnelles générées automatiquement à partir des images IRM.

L'objectif de ce projet étant de prédire l'état d'éveil à trois mois, il est nécessaire de disposer d'une vérité terrain permettant de répartir les patients en deux groupes pour l'entraînement des modèles de machine learning.

Pour cela, nous utilisons un tableau récapitulatif renseignant, pour chaque sujet, l'état d'éveil au troisième mois d'hospitalisation. Trois cas sont possibles :

- 1: le patient est éveillé,
- 0: le patient est non éveillé,
- NA: le patient est décédé avant l'évaluation.

Dans notre cohorte, 6 patients présentent une annotation NA. Après discussion avec le [Dr Florent Gobert](#), il a été décidé, pour cette étude, d'inclure les patients décédés dans le groupe "non éveil", dans la mesure où l'objectif clinique est de prédire l'état de conscience.

Le **tableau 1** synthétise les informations démographiques et les types de données disponibles pour chaque patient.

	IRM T1	IRM T2 FLAIR	PET	ASL	DTI	Masques des lésions cérébrales	Age	Poids moyen	Repartition sexe	Etat de conscience initial	Etat de conscience a 3 mois
Nombre / Valeur	71	71	70	71	71	71	Moyenne: 47 Plus bas: 18 Plus haut: 75	74,014 kg	27 femmes 44 hommes	55 en 0 14 en 1 1 en NA	28 en 0 36 en 1 6 en NA

Tableau 1: Liste non exhaustives des informations disponibles sur la cohorte d'étude

L'inclusion des patients suit une chronologie précise: les patients arrivent à l'hôpital dans le coma, sont ensuite sédatisés pour prolonger l'état comateux le temps de stabiliser les fonctions physiologiques vitales. Une fois la sédation arrêtée, deux issues sont possibles: soit le patient décède (et n'est pas inclus dans le protocole d'étude), soit il survit. Dans ce dernier cas, le patient peut être inclus dans le protocole de recherche et une batterie d'examen est réalisée dans les 7 jours suivant l'arrêt de la sédation (imagerie multimodale, tests cliniques et neurofonctionnels) [\[Annexe 1\]](#).

6.1. Protocole d'acquisition et prétraitement des images

Toutes les images étudiées dans le cadre de ce stage ont été acquises à l'aide d'une caméra hybride Siemens Biograph mMR à 3 Tesla (CERMEP, Bron, France).

6.1.1. IRM anatomique

Les deux séquences T1w et FLAIR ont été acquises selon les protocoles suivants :

- T1 : avec TR = 2300 ms, TE = 2.35 ms, TI = 900 ms, angle de bascule = 8°
- T2 FLAIR SPACE : avec TR = 5000 ms, TE = 396 ms, TI = 1800 ms, angle de bascule = 120°, train d'écho = 259

Les deux volumes présentent une résolution isotrope ou quasi-isotrope, avec des dimensions respectives de 176x256x256 voxels pour la T1w et 176x512x512 voxels pour la FLAIR. Les tailles de voxel sont d'environ 1,0x0,98x0,98 mm³ pour la T1w, et 1,0x0,5x0,5,mm³ pour la FLAIR, favorisant une résolution accrue dans les plans axiaux pour la détection de lésions.

Les images ont été converties en NIfTI-1+ à l'aide de l'outil *dcm2nii*, sans recalibrage d'échelle (*scl_slope* = 1, *scl_inter* = 0), garantissant l'intégrité des intensités originales.

6.1.2. IRM de perfusion

Les données ont été acquises avec une résolution spatiale de 3,44x3,44x6,0 mm³, sur un volume de 64x64x21 voxels, et une séquence dynamique de 90 volumes, avec un pas temporel de 3,8 s.

Le prétraitement a été effectué via la pipeline Oxford ASL (FSL), comprenant :

- une correction des mouvements intra-scan
- une normalisation par l'image M₀,
- l'application d'un modèle cinétique standard pour le calcul du CBF quantitatif (en ml/100g/min)
- la génération de cartes voxel-wise de perfusion cérébrale.

Enfin, les cartes CBF ont été recalées et ré-échantillonnées sur l'image anatomique T1 correspondante, afin de permettre une analyse multimodale conjointe avec les autres modalités.

6.1.3. IRM de diffusion

L'image de diffusion est un volume 4D présentant une dimension spatiale de 114 × 114 × 71 voxels et comportant 65 volumes, correspondant à une série d'acquisitions avec différentes directions de gradients de

diffusion. L'espacement des voxels est isotrope dans le plan axial, avec une taille de $2.02 \times 2.02 \times 2.00 \text{ mm}^3$, ce qui assure une résolution suffisante pour l'analyse fine de la microstructure cérébrale.

Avant l'analyse tensorielle, les images subissent une étape de prétraitement comprenant notamment la correction des mouvements du sujet et des distorsions liées aux courants de Foucault, à l'aide de la commande *eddy* ou *topup* du logiciel FSL. Le tenseur de diffusion est ensuite estimé voxel par voxel à l'aide de *dtifit*, produisant les trois valeurs propres λ_1 , λ_2 et λ_3 . Ces valeurs propres correspondent aux coefficients de diffusion selon les axes principaux de diffusion, avec λ_1 représentant la diffusion axiale, et λ_2 , λ_3 les composantes radiales.

6.1.4. TEP - ImgCMRGlu

Les images dynamiques ont été acquises selon un protocole d'acquisition continue immédiatement après injection, permettant de suivre l'évolution temporelle de la distribution du traceur dans le cerveau.

Un recalage rigide a été effectué avec *flirt* (FSL) entre l'image moyenne TEP et l'image anatomique T1 correspondante. Ce recalage permet le transfert précis des régions d'intérêt (ROI) segmentées en IRM vers l'espace TEP. L'évolution de la concentration du traceur dans ces régions a ensuite été extraite sous forme de TAC (Time-Activity Curves), représentant la courbe d'activité radioactive en fonction du temps.

Enfin, les paramètres dynamiques ont été utilisés pour modéliser la consommation métabolique cérébrale de glucose (CMRGlu) selon un modèle cinétique standard, ajusté à chaque voxel. A noter que la courbe de concentration plasmatique (Cp) correspond à la concentration du traceur dans le sang artériel au cours du temps et constitue l'entrée nécessaire aux modèles cinétiques utilisés pour quantifier le CMRGlu. Le résultat de cette modélisation est une carte voxel-wise du CMRGlu, où chaque pixel encode une valeur quantitative (exprimée en $\mu\text{mol}/100\text{g}/\text{min}$), traduisant localement l'activité métabolique cérébrale.

6.2. Segmentation des structures cérébrales régionales et des lésions

6.2.1. Parcellisation regionales

Des atlas de parcellisation cérébrale, nommées *Hammers* [8], servent de référence pour segmenter le cerveau des patients en régions anatomiques distinctes à partir d'IRM T1 [Annexe 2a]. Deux niveaux de parcellisation sont disponibles : une segmentation standard en 83 régions [Annexe 2b], et une version plus détaillée en 141 régions qui différencie matière grise et matière blanche (atlas WMGM) [Annexe 2c]. Ces atlas sont alignés sur l'espace d'IRM T1 de chaque patient pour transférer les labels anatomiques, permettant ainsi une extraction régionale des mesures issues des différentes modalités d'imagerie (diffusion, perfusion, métabolisme), et offrant une analyse locale et anatomiquement interprétable des biomarqueurs cérébraux.

6.2.2. Segmentation lésionnelle

Une étape clé du protocole consiste à segmenter les lésions cérébrales, tâche confiée à l'entreprise *Pixyl*. Celle-ci a développé trois modèles de segmentation automatique de lésions cérébrales.

Le premier modèle est basé sur un réseau de neurone entraîné de manière supervisée sur des données IRM T1 de patients atteints de glioblastome. Il génère une segmentation lésionnelle des glioblastomes en trois

labels distincts. Dans le cadre de notre étude, les labels 1 et 3 représentent des néo-volumes intracérébraux, tandis que le label 2 correspond aux lésions parenchymateuses.

Les deux autres modèles produisent des cartes de probabilité à partir des images T2-FLAIR, préalablement recalées dans l'espace T1. Ces cartes indiquent, pour chaque voxel, la probabilité d'être un hypersignal pathologique (quelle que soit la pathologie) ou spécifique à la sclérose en plaques.

Pixyl a fourni les segmentations lésionnelles pour 71 patients de la cohorte.

Par la suite, [Clémence Bobichon](#) (doctorante) a défini manuellement et pour chaque patient, des seuils pour chaque type de carte de probabilité. Elle a également annoté à la main les régions correspondant au label 4 sur les cartes des glioblastomes, représentant des néo-volumes extra-cérébraux. Ces lésions extra-cérébrales sont situées en dehors du tissu cérébral et sont exclues de l'analyse fonctionnelle et structurelle de l'intégrité du cerveau, car l'hypothèse est faite qu'elles ne participent pas directement à l'altération de la conscience.

En parallèle, elle a procédé à un contrôle qualité systématique des segmentations. En cas de segmentation incorrecte, une correction manuelle des lésions a été réalisée ; si celle-ci s'avérait impossible, le patient était exclu de l'étude.

7. MÉTHODES

Un pipeline de traitement des images a été développé en Python pour automatiser les différentes étapes de prétraitement et d'analyse des images médicales. Chaque étape correspond à un script indépendant, lancé dans un ordre précis via un programme principal qui gère leur exécution. L'utilisateur peut choisir de lancer l'ensemble du pipeline, uniquement la phase de prétraitement, la phase d'analyse, ou bien une étape spécifique selon ses besoins. Les scripts sont exécutés de manière sécurisée avec capture des sorties et des erreurs, ce qui permet d'interrompre le processus immédiatement en cas de problème. Toutes les sorties sont enregistrées dans un fichier de log, garantissant ainsi une bonne traçabilité du travail effectué. Après la création automatique des sous-dossiers destinés à recevoir les segmentations manuelles, le pipeline propose une interaction simple pour copier les fichiers dans les bons dossiers, ce qui facilite l'intégration des données manuelles. Les chemins d'accès aux fichiers et aux scripts sont centralisés en début de code, ce qui rend le pipeline facilement adaptable à différents environnements. Enfin, des codes couleur sont utilisés pour rendre le suivi du processus plus clair et aider à repérer rapidement les erreurs dans le terminal. Cette architecture modulaire et robuste permet d'assurer la reproductibilité et la flexibilité du traitement d'images dans un contexte de recherche clinique. [\[Annexe 3\]](#)

7.1. **Prétraitement des données**

L'objectif est d'utiliser l'ensemble des images paramétriques modélisées et prétraitées issues des données disponibles (présentées dans la sous-section [6.1](#)) afin de calculer la charge lésionnelle par région, de générer de nouvelles cartes paramétriques, puis de les recalculer ou de les ré-échantillonner dans l'espace T1. Cette harmonisation vise à standardiser l'intégration intermodale et d'assurer la comparabilité des résultats.

7.1.1. **IRM T1 et T2 FLAIR - Segmentation lésionnelle**

Dans la cohorte analysée dans ce rapport, la majorité des sujets présentent des lésions cérébrales. Celles-ci peuvent être regroupées en deux catégories principales: les hématomes, qui correspondent à des

accumulations de sang dans le parenchyme cérébral à la suite d'une hémorragie; et les œdèmes, qui résultent d'une infiltration excessive de liquide, en général de l'eau, provoquée par une réaction inflammatoire ou traumatique.

À partir des images pondérées en T1 et FLAIR, un pipeline de traitement (**figure 4**) a été mis en place pour permettre la segmentation et la catégorisation automatique des lésions cérébrales.




Figure 4: Pipeline de prétraitement des images paramétriques issues des IRM T1 et FLAIR

Les seuils définis manuellement sont appliqués aux deux images de probabilité issues de la T2-FLAIR. Ces cartes seuillées sont ensuite fusionnées pour générer un masque unique, nommé "mask_FLAIR.nii.gz".

La catégorisation des lésions repose sur des opérations d'union et d'intersection entre les quatre labels de la segmentation des glioblastomes et le "mask_FLAIR". Cette étape permet de produire quatre masques distincts:

- Hématome: union des labels 1 et 3 de segmentation glioblastome,
- Œdème parenchymateux: intersection du label 2 de la segmentation glioblastome avec le "mask_FLAIR",
- Lésion totale: addition des masques d'hématome et d'œdème,
- Lésion extra-cérébrale: label 4 de la segmentation glioblastome, si présent.

Le masque extra-cérébral ne représente pas une structure cérébrale analysable. Il peut s'agir par exemple de résidus liés à une intervention chirurgicale ou d'artefacts post-opératoires. Ce masque n'est donc pas intégré dans l'analyse des lésions cérébrales proprement dites, mais il est utilisé pour exclure ces régions non interprétables de toutes les cartes paramétriques générées par la suite, afin de restreindre l'analyse aux seules zones cérébrales pertinentes.

Cette étape permet donc d'extraire des masques lésionnels catégorisés.

7.1.2. TEP au FDG et IRM de perfusion

Les images quantitatives issues de la TEP au FDG et de l'IRM de perfusion ASL subissent un ré-échantillonnage (illustré sur la **figure 5**).

Ces deux cartes paramétriques contiennent des valeurs quantitatives absolues ayant une signification physiologique (par exemple: $\mu\text{mol}/100\text{g}/\text{min}$ pour le FDG, $\text{ml}/100\text{g}/\text{min}$ pour la perfusion). Afin d'aligner ces

images sur l'anatomie du sujet, sans en altérer les intensités, un script de rééchantillonnage spatial est appliqué. Ce script utilise la fonction *reg_resample*, avec une interpolation cubique et un padding à zéro, pour projeter les images dans l'espace de l'IRM T1 native du sujet.

Il est essentiel de souligner que ce prétraitement n'applique aucune normalisation d'intensité: les valeurs issues de la quantification sont conservées afin de garantir la validité des analyses physiopathologiques ultérieures. Les deux images résultantes peuvent alors être directement comparées à d'autres modalités structurales ou fonctionnelles dans l'espace T1, tout en maintenant leur intégrité quantitative.




Figure 5: Pipeline de prétraitement des images paramétrique issues de la TEP et de l'IRM de perfusion

Cette étape fournit donc des cartes quantitatives du métabolisme cérébral (TEP au FDG) et du débit sanguin cérébral (ASL), projetées dans l'espace T1 pour analyse multimodale.

7.1.3. IRM de diffusion

Le pipeline de prétraitement est illustré en *figure 6*.




Figure 6: Pipeline de prétraitement des images paramétrique issues de l'IRM de diffusion

À partir des valeurs propres ($\lambda_1, \lambda_2, \lambda_3$) du tenseur, le calcul des cartes scalaires Fractional Anisotropy (FA), Mean Diffusivity (MD), Axial Diffusivity (AD), et Radial Diffusivity (RD) ont pu être réalisés selon les formules suivantes:

FA (Fractional Anisotropy) – degré d'anisotropie de la diffusion (intégrité des fibres) sans unité (entre 0 et 1)	$FA = \sqrt{\frac{1}{2}} \sqrt{\frac{(\lambda_1 - \bar{\lambda})^2 + (\lambda_2 - \bar{\lambda})^2 + (\lambda_3 - \bar{\lambda})^2}{\lambda_1^2 + \lambda_2^2 + \lambda_3^2}}$
MD (Mean Diffusivity) – diffusion moyenne indépendante de la direction (souvent noté en $10^{-3} \text{ mm}^2/\text{s}$)	$MD = \bar{\lambda} = \frac{\lambda_1 + \lambda_2 + \lambda_3}{3}$
AD (Axial Diffusivity) – diffusion principale (souvent noté en $10^{-3} \text{ mm}^2/\text{s}$)	$AD = \lambda_1$
RD (Radial Diffusivity) – diffusion perpendiculaire à l'axe principal (souvent noté en $10^{-3} \text{ mm}^2/\text{s}$)	$RD = \frac{\lambda_2 + \lambda_3}{2}$

Ces cartes fournissent des indices complémentaires sur l'état microstructural des tissus: la FA reflète l'organisation directionnelle des fibres ; la MD est sensible aux variations globales de diffusion (par exemple en cas d'œdème) ; l'AD est associée à l'intégrité axonale ; et la RD est considérée comme un marqueur indirect de la myélinisation (Processus de formation de la gaine de myéline autour des axones, contribuant à une conduction nerveuse rapide et efficace. Elle joue un rôle clé dans le développement cérébral et l'intégrité fonctionnelle des fibres nerveuses.)

Après calcul, chaque carte a été recalée dans l'espace T1 natif pour permettre une analyse intermodale. Cette étape inclut dans l'ordre:

1. le recalage rigide (6 degrés de liberté) de l'image anatomique T1 dans l'espace DWI (grâce à la fonction flirt de fslmaths),
2. un masquage par le cerveau extrait,
3. un recalage inverse des images DWI dans l'espace T1,
4. seuillage à 0 pour supprimer les valeurs négatives issues de l'interpolation

Cette étape permet donc la création des cartes des paramètres microstructuraux FA, MD, AD et RD,.

7.1.4. Carte de parcellisation

7.1.4.1. Parcellisation Hammers

L'ensemble du processus de génération et d'adaptation des cartes de parcellisation est illustré dans la *figure 7*.




Figure 7: Pipeline de prétraitement des images paramétriques issues de la TEP et de l'IRM de perfusion

L'intégration de l'impact des lésions sur la parcellisation se fait à partir de la parcellisation anatomique *Hammers*. Des masques lésionnels sont appliqués successivement à la parcellisation anatomique pour enlever les zones d'hématome (donnant la carte corrigée CP_hammersWMGM_masked.nii.gz) puis d'œdème (donnant la carte corrigée CP_hammersWMGM_masked_all.nii.gz). Ce pipeline permet ainsi de produire des cartes de parcellisation personnalisées, ajustées à la topographie lésionnelle de chaque patient, tout en conservant une structure régionale cohérente et adaptée à l'analyse quantitative.

Le choix de la carte de parcellisation finale utilisé dans l'analyse dépend du type d'examen et de la nécessité ou non de prendre en compte les lésions précédemment segmentées.

7.1.4.2. Parcellisation macroscopique CRF

Des discussions approfondies avec le [Dr Florent Gobert](#), ont mis en évidence la possibilité de fusionner certaines régions sans perte significative d'information grâce à la carte de parcellisation CRF. Cette carte de parcellisation est donc réalisée afin de proposer un découpage du cerveau en 56 régions macroscopiques. Elle est basée sur les désignations anatomiques cérébrales définies dans le Case Report Form (CRF) de l'étude de

recherche clinique IMAGINA. Cette carte reflète les régions qui sont étudiées lors du remplissage de la fiche clinique que les médecins doivent remplir lors de l'évaluation de l'état de coma du patient. Il présente l'avantage d'offrir un bon compromis entre précision anatomique et réduction de la complexité dimensionnelle. A partir des cartes de parcellisation *Hammers*, le regroupement de région est donc faite pour correspondre à cette nouvelle parcellisation notée *CRF* (illustré en **figure 8**)




Figure 8: Pipeline de conversion de la parcellisation Hammers à la parcellisation macroscopique CRF

Les étapes de traitement et d'analyse suivantes sont donc effectuées à partir de ces cartes de parcellisation *CRF*.

7.2. Extraction des caractéristiques

Une fois les étapes préliminaires réalisées, plusieurs informations peuvent être extraites à partir des images. Pour chaque carte paramétrique, des tableaux de données sont générés à partir des différentes valeurs extraites pour chaque région anatomique. Ces tableaux sont ensuite regroupés entre les deux groupes définis précédemment: patients éveillés et patients non éveillés.

7.2.1. Segmentation lésionnelle (IRM T1 et T2 FLAIR)

Nous appliquons le masque de lésion totale à la carte de parcellisation CRF matière blanche - matière grise (CRF_WMGM) afin de calculer la charge lésionnelle. Celle-ci est définie comme le pourcentage de chaque région de la carte de parcellisation affectée par la lésion. Pour cela, nous calculons deux quantités :

→ Chevauchement entre la lésion et la région de la carte de parcellisation :

$$overlap_lesion_total = \sum_{i,j,k} 1_{\{CP_{CRF_WMGM}(i,j,k)=l\}} \cdot 1_{\{Lesion_totale(i,j,k)=1\}}$$

→ Nombre total de voxels dans la région considérée :

$$total_voxels = \sum_{i,j,k} 1_{\{CP_{CRF_WMGM}(i,j,k)=l\}}$$

Avec :

- $CP_{CRF_WMGM}(i,j,k)$: la valeur du voxel en position (i,j,k) dans la carte de parcellisation *CRF_WMGM*
- l : le label de la région anatomique considérée
- $Lesion_totale(i,j,k)$: la valeur (0 ou 1) du masque binaire de la lésion totales à la position (i,j,k)

- $1\{\cdot\}$: la fonction indicatrice valant 1 si la condition est vraie, 0 sinon

Le produit des deux fonctions indicatrices permet donc de ne sélectionner que les voxels appartenant simultanément à la lésion et à la région anatomique d'intérêt.

→ Pourcentage de charge lésionnelle dans la région :

$$lesion_total_percentage = \frac{overlap_lesion_total}{total_voxels} * 100$$

On obtient ainsi, pour chaque sujet, un tableau. Ce dernier indique, pour chaque région cérébrale identifiée par un label, le volume total en voxels, le nombre de voxels correspondant à une lésion et le pourcentage de la région affectée (charge lésionnelle CL). La **figure 9** présentée ci-dessous illustre ce processus, ainsi qu'un extrait d'un tableau de sortie.




Figure 9: Extraction du pourcentage de la charge lésionnelle

7.2.2. TEP au FDG et IRM de perfusion

Pour les modalités d'imagerie ASL (Arterial Spin Labeling) et TEP au FDG, l'analyse est réalisée après avoir exclu les voxels appartenant à l'hématome et à l'œdème, via l'application des masques correspondants sur la carte de parcellisation anatomique. En effet, comme mentionné précédemment, ces tissus lésés ne présentent plus de propriétés physiologiques interprétables, en particulier en termes de perfusion (ASL) ou de captation du FDG (TEP), et peuvent donc fausser l'analyse.

L'analyse est donc restreinte aux voxels sains de chaque région anatomique, c'est-à-dire ceux qui ne sont ni dans l'hématome ni dans l'œdème. Si une région est partiellement atteinte, seules les parties non lésées sont conservées.

Sur ces voxels filtrés, plusieurs descripteurs statistiques sont extraits pour chaque région et chaque modalité :

- Moyenne: mesure la valeur moyenne d'intensité dans la région
- Écart-type: évalue la dispersion des intensités autour de la moyenne
- Maximum: valeur d'intensité maximale dans la région

- Pic d'intensité: moyenne des 3% des valeurs les plus élevées utilisée pour réduire l'influence des outliers tout en captant l'intensité maximale representative
- Médiane: valeur centrale des intensités une fois triées, robuste aux valeurs extrêmes.

Ces indicateurs permettent une caractérisation fine de l'activité fonctionnelle dans les régions cérébrales préservées, tout en minimisant l'impact des lésions sur l'analyse globale. La **figure 10** présentée ci-dessous illustre ce processus.




Figure 10: Extraction de tableaux de valeurs pour les images paramétriques issues de la TEP et de l'IRM de perfusion

Pour chaque sujet, un tableau est généré pour chaque image paramétrique (ASL et FDG).

7.2.3. IRM de diffusion

Pour cette modalité, l'analyse est restreinte aux voxels sains de chaque région anatomique, c'est-à-dire ceux situés en dehors de l'hématome et de l'œdème. L'extraction des données suit donc le même principe que pour l'IRM de perfusion et la TEP au FDG.

À partir de ces voxels filtrés, la valeur moyenne d'intensité est calculée pour chaque région anatomique et pour chaque carte de diffusion (FA, MD, AD et RD), permettant ainsi une quantification régionale précise.

Pour chaque sujet, les valeurs moyennes des différentes cartes de diffusion ont été extraites pour chaque région anatomique, et un tableau individuel a été généré par sujet comme illustré sur le **tableau 2**.

Region	FA	MD	AD	RD
1	0.18476	0.0009	0.00106	0.00083
2	0.1762	0.00089	0.00103	0.00082
3	0.22663	0.00076	0.00094	0.00068
4	0.20845	0.00073	0.00088	0.00065
5	0.17398	0.00086	0.00099	0.0008
6	0.17429	0.00082	0.00095	0.00076
7	0.23336	0.00085	0.00103	0.00076

Tableau 2: Exemple de valeurs extraites pour chaque patient sur l'IRM de diffusion

7.2.4. Données manquantes

Deux types de données manquantes peuvent être rencontrés dans notre analyse : celles provenant des modalités fonctionnelles (IRM de perfusion, TEP au FDG) et celles liées à des problèmes de parcellisation anatomique.

Dans le premier cas, la donnée manquante correspond généralement à une absence totale de voxels valides dans une région anatomique, en raison d'une charge lésionnelle de 100 % (c'est-à-dire que toute la région est affectée par une lésion). Pour ces cas rares, nous avons choisi de remplacer les valeurs manquantes par zéro. Cette décision repose sur plusieurs éléments. Tout d'abord, le nombre de cas concernés est très faible par rapport au nombre total de données. Ensuite, supprimer les régions concernées pour tous les sujets, ou supprimer les modalités pour le patient concerné, aurait entraîné une perte significative d'information. Enfin, le remplacement par zéro est cohérent sur le plan physiopathologique: une région entièrement lésée est censée ne plus présenter d'activité métabolique, ni de perfusion ni de diffusion. Cette approche permet ainsi de conserver l'ensemble des régions et des patients dans l'analyse, sans introduire de biais majeur.

Dans l'autre cas, l'absence de valeur peut être due à des problèmes dans la carte de parcellisation (par exemple, une région absente dès l'étape de segmentation [\[Annexe 4\]](#) ou à des artefacts d'acquisition affectant certaines modalités (perfusion mal enregistrée, artefacts de mouvement, etc.)[\[Annexe 5\]](#). Ici, nous remplaçons la valeur manquante par la moyenne des valeurs de cette même région, calculée uniquement parmi les sujets du même groupe (par exemple, groupe "éveil" ou "non éveil"). Cela permet d'éviter l'introduction d'un biais intergroupe lors de l'imputation.

7.3. Analyse statistiques et visualisation des données

Afin d'évaluer le pouvoir discriminant de chaque modalité d'imagerie à distinguer les groupes "éveil" et "non éveil", une analyse multivariée de la variance (MANOVA, Multivariate Analysis of Variance [\[9\]](#)) a été réalisée séparément pour chacune des cinq modalités disponibles : charge lésionnelle (CL), ASL, FDG, FA et MD.

La MANOVA est une extension de l'ANOVA qui permet de tester si un facteur (ici, le groupe clinique) a un effet significatif sur plusieurs variables dépendantes simultanément (les mesures régionales d'une même modalité). Elle est particulièrement utile pour détecter des différences globales de patterns entre groupes. L'analyse a été effectuée à l'aide de la fonction *MANOVA* du module *statsmodels.multivariate*.

Pour chaque modalité, la MANOVA a été appliquée sur l'ensemble des régions disponibles (par exemple, les différentes régions de la parcellisation macroscopique CRF pour la charge lésionnelle). Les tests multivariés utilisés [\[10 p.5-7\]](#) incluent :

- Wilks' Lambda : le plus couramment utilisé ; il mesure la variance non expliquée par le facteur. Une valeur faible indique une forte différence entre groupes.
- Pillai's Trace : robuste aux violations des hypothèses ; mesure la part de variance expliquée.
- Hotelling-Lawley Trace et Roy's Greatest Root : autres statistiques classiques mesurant différentes combinaisons de variabilité inter- et intra-groupes.

Les valeurs de p associées à chaque test permettent d'évaluer la significativité globale de l'effet du groupe pour chaque modalité.

En complément des analyses statistiques, une visualisation des données a été réalisée par t-SNE (t-distributed Stochastic Neighbor Embedding), en 2D et en 3D, pour chaque modalité. Le t-SNE est une méthode de réduction de dimension non linéaire qui permet de projeter des données complexes (multivariées) dans un espace visuel (2 ou 3 dimensions) tout en préservant au mieux les relations locales entre les points. Autrement dit, si deux sujets sont proches dans l'espace des données originales, ils seront aussi proches dans la représentation t-SNE. Cette approche permet de visualiser la séparation potentielle entre les groupes "éveil" et "non éveil", en complément des résultats numériques de la MANOVA.

7.4. Modèles de classification par apprentissage automatique

L'objectif est d'évaluer les performances de plusieurs modèles de machine learning supervisé (binaire) pour classer les patients selon leur état de conscience à trois mois ('éveil' vs 'non éveil'), à partir des caractéristiques extraites lors de l'analyse statistique exploratoire. Une attention particulière est portée à la sélection des variables les plus discriminantes pour la tâche de classification, ainsi qu'à l'évaluation de l'apport de la multimodalité dans la performance des modèles. Cette démarche s'inscrit dans une approche de modélisation prédictive visant à mieux estimer le pronostic neurologique des patients.

7.4.1. Modèles de classification supervisée

Cinq algorithmes de classification supervisée binaire ont été implémentés à l'aide de la bibliothèque *sklearn* sous Python. Ces modèles ont été sélectionnés pour leur complémentarité en termes de complexité et de robustesse face à la dimensionnalité ou au bruit.

- SVM linéaire : algorithme à marge maximale permettant de trouver un hyperplan séparateur optimal entre les deux classes dans un espace linéaire. Il est efficace dans les cas de données peu bruitées et linéairement séparables.
- SVM à noyau RBF (Radial Basis Function) : extension non linéaire du SVM utilisant un noyau gaussien pour projeter les données dans un espace de dimension supérieure, permettant de capturer des frontières de décision complexes.
- Régression logistique : modèle linéaire probabiliste qui estime la probabilité d'appartenance à une classe via une fonction sigmoïde. Il est simple, interprétable, et sert de référence de base.
- Arbre de décision (Decision Tree): modèle non linéaire basé sur une structure hiérarchique de règles de décision. Il permet une interprétation intuitive des prédictions mais est sensible au surapprentissage.
- Forêt aléatoire (Random Forest) : ensemble d'arbres de décision construits sur des sous-échantillons aléatoires des données et des variables. Elle améliore la robustesse, réduit la variance, et limite le surapprentissage tout en maintenant une certaine capacité d'interprétation.

7.4.2. Plan d'expérience

Un pipeline d'apprentissage automatique structuré (voir **schéma 1**) a été mis en place afin de garantir la robustesse du protocole et d'éviter toute fuite de données (data leakage). Ce pipeline est composé de trois étapes principales.

La première étape consiste en une normalisation des variables à l'aide d'un *StandardScaler*, qui centre chaque variable autour de zéro et la réduit à une variance unitaire. Cette étape permet d'assurer que toutes les variables, quelle que soit leur échelle initiale, contribuent de manière équitable à l'apprentissage du modèle.

La seconde étape repose sur une sélection de variables destinée à réduire la dimensionnalité, éliminer le bruit, et améliorer la généralisation. Pour la majorité des modèles, cette sélection est réalisée via la méthode *SelectFromModel*, qui retient les variables jugées pertinentes par un estimateur régularisé. L'estimateur utilisé pour cette sélection correspond au modèle principal d'apprentissage, garantissant une cohérence entre les critères de sélection et la nature du classifieur. Par exception, pour le SVM à noyau non linéaire (RBF), la sélection est effectuée à l'aide de la méthode *SelectKBest*, qui retient un nombre fixe de variables présentant les scores univariés les plus élevés selon un test statistique.

Enfin, la troisième étape consiste en l'entraînement du modèle principal de classification, sur les données normalisées et réduites à l'ensemble de variables sélectionnées.

L'ensemble de ces étapes est encapsulé dans une recherche exhaustive d'hyperparamètres (*GridSearchCV*), permettant un ajustement automatique des modèles à chaque itération de validation croisée. Les hyperparamètres considérés concernent à la fois le modèle de sélection des variables et les algorithmes d'apprentissage supervisé. Afin d'assurer la transparence et la reproductibilité de l'analyse, une grille de recherche a été explicitement définie pour chaque modèle. Par exemple, pour la régression logistique, différentes valeurs de la régularisation ont été utilisées pour la sélection des caractéristiques ($select_estimator_C \in \{1, 10, 15, 20, 30, 50\}$) et pour le modèle ($model_C \in \{0.001, 0.01, 0.1, 1, 10, 50, 100\}$) ainsi que plusieurs solveurs ($model_solver \in \{'liblinear', 'lbfgs'\}$). Pour les modèles d'arbres de décision, les paramètres évalués incluent la profondeur maximale ($model_max_depth \in \{5, 10, 15, 20\}$) et le nombre d'estimateurs ($model_n_estimators \in \{50, 100\}$). Cette grille d'hyperparamètres est appliquée indépendamment dans chaque repli de validation croisée, garantissant que la sélection des variables et la normalisation soient réalisées sans contamination des ensembles de test par les ensembles d'entraînement.




Schéma 1: Pipeline d'apprentissage automatique

En raison du faible effectif de patients disponibles, une validation croisée stratifiée en 5 plis est utilisée afin de maximiser l'utilisation des données tout en conservant une estimation fiable de la performance. Une fois le meilleur ensemble d'hyperparamètres identifié, des prédictions de sortie (*cross_val_predict*) sont générées pour obtenir les classes prédites ainsi que les probabilités associées sur l'ensemble du jeu de données, toujours selon la stratégie de validation croisée. Ce protocole constitue une base rigoureuse pour toutes nos analyses supervisées.

7.4.3. Métriques d'évaluation

Les performances des modèles de classification sont évaluées à l'aide de plusieurs métriques standards, calculées sur les prédictions obtenues par validation croisée issues de la matrice de confusion, qui contient les catégories: vrais positifs (TP), vrais négatifs (TN), faux positifs (FP) et faux négatifs (FN). Chaque métrique permet de caractériser un aspect complémentaire du comportement prédictif du modèle.

- Exactitude : proportion d'échantillons correctement classés

$$\text{Exactitude} = \frac{TP + TN}{TP + TN + FP + FN}$$

- Précision : proportion de vrais positifs parmi les prédictions positives

$$\text{Précision} = \frac{TP}{TP + FP}$$

- Sensibilité : proportion de vrais positifs parmi les cas réellement positifs

$$\text{Sensibilité} = \frac{TP}{TP + FN}$$

- Spécificité : proportion de vrais négatifs parmi les cas réellement négatifs

$$\text{Spécificité} = \frac{TN}{TN + FP}$$

- Score F1 : moyenne harmonique entre la précision et la sensibilité

$$\text{Score F1} = 2 \frac{\text{Précision} \times \text{Sensibilité}}{\text{Précision} + \text{Sensibilité}}$$

- AUC (Area Under the Curve) : aire sous la courbe ROC (Receiver Operating Characteristic), qui trace la sensibilité en fonction du taux de faux positifs ($FPR = \frac{FP}{FP + TN}$) pour différents seuils de classification. L'AUC varie entre 0.5 (modèle aléatoire) et 1 (classification parfaite).

7.4.4. Evaluation des performances

Cette étape vise à comparer les performances des différents modèles de classification supervisée pour la prédiction de l'état de conscience (« éveil » vs « non éveil »). En parallèle, étant donné la diversité des modalités d'imagerie disponibles (IRM anatomique, IRM de diffusion, IRM de perfusion ASL, TEP au FDG, etc.), cette analyse permet également d'évaluer l'apport relatif de chaque modalité dans la performance des modèles.

Dans un objectif d'optimisation, une procédure automatisée a été mise en place afin d'évaluer de manière exhaustive l'ensemble des combinaisons possibles entre les modalités suivantes : charge lésionnelle (CL), ASL,

FDG, FA, et MD. Chaque combinaison est testée de manière isolée via un appel indépendant au modèle de classification, selon un script itératif. Un redémarrage explicite du noyau d'exécution est appliqué à chaque itération, associé à une vérification systématique des identifiants de processus. Cette stratégie garantit l'indépendance complète des tests, en éliminant tout risque de contamination croisée ou de rémanence de variables en mémoire, assurant ainsi la reproductibilité des résultats.

La sélection finale du modèle repose exclusivement sur la valeur moyenne de l'aire sous la courbe ROC (AUC), mesurée par validation croisée. En effet, l'AUC est un critère de choix permettant d'évaluer les modèles prédictifs, car elle résume en un seul chiffre la capacité du modèle à bien classer les patients, quelles que soient les variations du seuil de décision.

L'enjeu est de déterminer quelles modalités, seules ou combinées, sont les plus informatives pour la prédiction de l'état d'éveil, et d'identifier les types de données et régions cérébrales les plus contributives dans ce cadre.

8. RÉSULTATS

8.1. **Prétraitement des données**

Un travail de contrôle qualité visuel a été réalisé sur les segmentations lésionnelles, les cartes paramétriques de perfusion (ASL), du métabolisme glucidique (TEP au FDG) et de l'intégrité de fibres de matière blanche (IRM de diffusion).

8.1.1. **IRM T1 et T2 FLAIR - Segmentation lésionnelle**

Le pipeline de segmentation et de catégorisation des lésions cérébrales, décrit en section 7.1.1, a été appliqué à un ensemble de 63 sujets (8 segmentations ne sont pas exploitables).

Parmi ces 63 sujets, seuls deux présentaient une lésion extra-cérébrale détectée par le modèle. Un exemple représentatif de ce type de lésion est illustré sur la **figure 11**. Ces lésions extra-cérébrales ont été systématiquement exclues des analyses quantitatives afin de restreindre l'étude aux structures cérébrales pertinentes.




Figure 11: Exemple de sujet ayant une lésion extra cérébrale qui a été enlevé de la carte de parcellisation

Ainsi, après exclusion des patients dont les segmentations de lésions étaient insuffisamment exploitables, la cohorte initiale de 71 examens a été réduite à 63 examens.

8.1.2. TEP au FDG et IRM de perfusion

Le pipeline de prétraitement des données TEP au FDG et IRM de perfusion ASL, décrit en section 7.1.2, a été appliqué sur un total de 71 patients. À l'issue du traitement, 58 patients ont pu être inclus dans l'analyse de perfusion, les autres ayant été écartés en raison d'artefacts de bande affectant les images ASL [Annexe 6]. Concernant la TEP au FDG, les données de 70 patients ont été retenues: un sujet a été exclu car la courbe plasmatique (Cp) associée était trop courte pour permettre une modélisation fiable des paramètres métaboliques.

8.1.3. IRM de diffusion

Le traitement des données d'IRM de diffusion, décrit en section 7.1.3, a été mené sur les 71 patients inclus dans l'étude. Pour l'ensemble des sujets, les cartes paramétriques de fraction d'anisotropie (FA), de diffusivité moyenne (MD), de diffusivité axiale (AD) et de diffusivité radiale (RD) ont pu être obtenues après correction des données et recalage sur les images anatomiques.

Ainsi, comme l'analyse repose sur une approche multimodale, seuls les patients disposant de l'ensemble des examens ont été retenus, ce qui conduit à une cohorte finale de 52 patients (*figure 12*).




Figure 12: Diagramme du contrôle qualité sur les différentes modalités

Note: Ce nombre total de patients n'a été pris en compte qu'à partir de la mi-juin. Auparavant, seuls 43 sujets étaient disponibles, et 7 patients supplémentaires sont encore en attente, leurs segmentations devant être reprises manuellement.

8.1.4. Carte de parcellisation

8.1.4.1. Parcellisation Hammers

À partir de la parcellisation cérébrale fine en 141 régions (*Hammers*), chaque sujet est caractérisé par 141 valeurs par image 3D. En considérant les sept modalités disponibles (incluant la charge lésionnelle, la captation du FDG, le débit sanguin mesuré par ASL, ainsi que les valeurs des cartes d'imagerie de diffusion telles que FA, MD, AD et RD), le jeu de données final comprend 987 variables par sujet sachant qu'après exclusion des sujets présentant des données manquantes, l'analyse est menée sur 52 patients (cf *figure 12*).

Pour répondre à cette problématique de déséquilibre entre nombre de variables et nombre d'observations, deux axes de réflexion complémentaires ont été explorés. Le premier consiste à limiter le nombre de modalités conservées pour l'analyse, en sélectionnant uniquement celles apportant une information discriminante significative. Cette piste sera analysée au moment de l'utilisation de modèle de machine learning (cf paragraphe 8.4). Le second vise à réduire le nombre de régions anatomiques, en regroupant celles qui présentent une cohérence anatomique ou fonctionnelle ou dont la distinction n'apporte aucune information supplémentaire. Cette seconde approche est rendue possible grâce à l'utilisation des cartes de parcellisation CRF.


8.1.4.2. Parcellisation macroscopique CRF

L'utilisation de la carte de parcellisation CRF a permis de réduire le nombre total de variables à 392 par patient (soit 56 régions x 7 cartes paramétriques), rendant l'analyse plus traitable d'un point de vue statistique et computationnel, tout en préservant une richesse informative.

8.2. Extraction des caractéristiques

8.2.1. Segmentation lésionnelle (IRM T1 et T2 FLAIR)

Plusieurs analyses ont été menées sur la charge lésionnelle au sein de la cohorte de 63 patients présentant des segmentations exploitables. Ces analyses comprennent l'affichage de boxplots des volumes (en voxels) de chaque région au sein de la cohorte [Annexe 7], des occurrences des régions atteintes par une lésion au sein de la cohorte [Annexe 8], des valeurs moyennes des charges lésionnelles par région (ordonnées par le nombre de sujet concerné) [Annexe 9] et de l'évolution des charges lésionnelles en fonction des régions chez tous les patients [Annexe 10]. L'exploration de différentes représentations de la distribution de la charge lésionnelle par région anatomique a permis d'identifier certaines régions se distinguant par une atteinte particulièrement marquée, soit en raison d'une charge lésionnelle élevée, soit par leur fréquence d'atteinte au sein de la cohorte. Ainsi, des cartes de chaleur ont été générées afin de visualiser de manière synthétique et globale la répartition spatiale des lésions dans l'ensemble des régions cérébrales, offrant ainsi une vue d'ensemble du profil topographique des atteintes à l'échelle de la population étudiée.



*Figure 14: Cartes de chaleur des
groupe éveil (haut) et non éveil (bas)
en fonction des régions
La région 30 est mise en évidence*

Des analyses similaires ont été menées en distinguant les types de lésions, notamment l'hématome et l'œdème [Annexes 12 et 13]. Toutefois, la séparation de ces entités n'a pas conduit à des résultats significativement différents. Afin de réduire la dimensionnalité des données sans compromettre la pertinence clinique, la charge lésionnelle calculée à partir de la lésion totale a été retenue pour les analyses subséquentes. Cette approche globalisée permet une évaluation robuste de l'atteinte cérébrale, tout en maintenant une granularité suffisante pour les analyses quantitatives ultérieures.

8.2.2. TEP au FDG et IRM de perfusion

Ces données ont servi de base à la différenciation des groupes éveil des non-éveil [Annexes 14 et 15]. En appliquant les données cliniques à notre cohorte de 58 patients, on obtient ainsi 33 patients dans le groupe éveil et 25 dans le groupe non éveil. En raison de l'absence de différences marquées selon les différentes métriques étudiées, l'analyse a été restreinte aux valeurs moyennes des deux modalités, dans un objectif de réduction de la dimensionnalité.



Figure 15: Boxplots des moyennes de perfusion et de TEP-FDG par régions en fonction des groupes éveil et non éveil

Les résultats de la **figure 15** ne montrent pas de distinction significative entre les groupes éveil et non éveil. Ainsi, aucune région ne présente de distribution permettant de discriminer de manière fiable les deux groupes sur les boxplots analysés.

8.2.3. IRM de diffusion

Ces données ont servi de base à la comparaison entre les groupes éveil et non éveil pour chaque type de carte de diffusion [\[Annexe 16\]](#). En appliquant les données cliniques à notre cohorte de 71 patients, on obtient ainsi 37 patients dans le groupe éveil et 34 dans le groupe non éveil. Cependant, toujours par souci de réduction de la dimensionnalité, l'analyse a été restreinte aux cartes de fraction d'anisotropie (FA) et de diffusion moyenne (MD). Ce choix repose à la fois sur les résultats des analyses statistiques préliminaires et sur les données de la littérature, qui indiquent que les cartes FA et MD sont les plus couramment utilisées pour caractériser les altérations microstructurales des tissus cérébraux, tandis que les cartes d'anisotropie radiale (RD) et de diffusion axiale (AD) sont moins fréquemment exploitées dans ce type d'étude. [\[6\]\[11\]\[12\]](#)




Figure 16: Boxplots des moyennes de diffusion par régions en fonction des groupes éveil et non éveil

Globalement, on observe sur la **figure 16** que les boxplots du groupe *non éveil* présentent des valeurs de FA plus faibles que celles du groupe *éveil*, tandis que pour les cartes MD, la tendance est inverse. Toutefois, ces différences restent peu significatives et ne permettent pas une discrimination robuste entre les deux groupes.

8.2.4. Données manquantes

Le passage de la carte de parcellisation Hammers à la carte de parcellisation CRF a permis de réduire significativement le nombre de données manquantes. Avec la carte de parcellisation Hammers, nous avons initialement 39 valeurs manquantes imputées à zéro, en raison d'une charge lésionnelle de 100 % dans les régions concernées. Deux autres valeurs manquantes ont été imputées à la moyenne des patients du même groupe d'éveil, car elles résultent d'une mauvaise parcellisation de régions trop petites.

En adoptant la carte de parcellisation CRF, qui regroupe certaines petites régions en entités plus larges, nous avons considérablement limité ces cas problématiques. Finalement, seules deux valeurs manquantes ont été observées avec la carte de parcellisation CRF, toutes deux imputées à zéro car elles correspondaient également à une charge lésionnelle totale.

8.3. Analyse statistiques et visualisation des données

Les résultats des analyses MANOVA [\[Annexe 17\]](#) appliquées séparément à chaque modalité sur la cohorte finale de 52 sujets sont synthétisés ci-dessous :

Modalité/valeur étudiée	p-value
Charge lésionnelle	p = 0.1778
ASL	p = 0.2707
FDG	p = 0.6137
FA	p = 0.4899
MD	p = 0.9736

Parmi les modalités étudiées, aucune ne présente de différence statistiquement significative entre les groupes (toutes les p-values sont supérieures à 0.05). La charge lésionnelle a la plus faible p-value (0.1778)

mais reste néanmoins loin d'un niveau de significativité acceptable. À l'inverse, la modalité MD affiche la p-value la plus élevée (0.9736), soulignant un manque total de pouvoir discriminant dans ce cadre.

La visualisation de la répartition des données à l'aide du t-SNE permet d'illustrer ces constats statistiques. Pour la charge lésionnelle, les projections en 2D et en 3D (**figure 17**) ne révèlent aucune séparation marquée entre les deux groupes.




Figure 17: Représentation t-SNE en 2D et 3D des mesures régionales pour la charge lésionnelle

De même, la modalité MD, les projections t-SNE (**figure 18**) montrent un fort recouvrement des groupes, traduisant une capacité plus limitée à discriminer visuellement les états de conscience.




Figure 18: Représentation t-SNE en 2D et 3D des mesures régionales pour la modalité IRM de diffusion - MD

Les projections t-SNE associées aux autres modalités (ASL [\[Annexe 18\]](#), FDG [\[Annexe 19\]](#), FA [\[Annexe 20\]](#)) sont fournies en annexe pour consultation complémentaire.

Ces résultats exploratoires renforcent l'idée que, prises isolément, les modalités évaluées ne permettent pas de différencier efficacement les états de conscience. Cela motive l'exploration d'approches multimodales, où la combinaison des sources d'information pourrait améliorer la sensibilité et la robustesse de la classification clinique.

8.4. Modèles de classification par apprentissage automatique

Pour tous les modèles de machine learning, l'entraînement et le test ont été réalisés sur une cohorte de 52 sujets, correspondant aux seuls patients disposant de l'ensemble des modalités disponibles. Parmi eux, 30 appartiennent au groupe "éveil" et 22 au groupe "non éveil". Après extraction (section 8.3) et combinaison de toutes les caractéristiques, le nombre maximal de variables atteint 280, correspondant aux cinq types de mesures suivantes : charge lésionnelle, ASL, PET FDG, ainsi que les cartes FA et MD issues de l'IRM de diffusion, évaluées pour chacune des 56 régions définies par la parcellisation Hammers ($5 \times 56 = 280$).

8.4.1. Plan d'expérience


La sélection (section 7.4.2) effectuée par le modèle de l'arbre de décision (*figure 20*) est utilisée comme exemple de sortie représentative que chaque modèle peut fournir.

```
Dimension apres selection: 19
[ 7  8 11 14 17 130 137 143 144 148 157 209 212 229 250 251 261 264
 272]
Feature idx 7: Modalité LL, Région 8 = Pédoncule cérébelleux moyen : Gauche
Feature idx 8: Modalité LL, Région 9 = Mésencéphale Pédoncule
Feature idx 11: Modalité LL, Région 12 = Occipitale : Gauche
Feature idx 14: Modalité LL, Région 15 = Cingulaire antérieure : Droite
Feature idx 17: Modalité LL, Région 18 = Frontale moyen : Gauche
Feature idx 130: Modalité MD, Région 19 = Frontale moyen : Droite
Feature idx 137: Modalité MD, Région 26 = Thalamus : Gauche
Feature idx 143: Modalité MD, Région 32 = Frontale supérieur latérale : Gauche
Feature idx 144: Modalité MD, Région 33 = Frontale inférieur : Droite
Feature idx 148: Modalité MD, Région 1001 = WM Hippocampe et gyrus para-hippocampique : Droite
Feature idx 157: Modalité MD, Région 1015 = WM Cingulaire antérieure : Droite
Feature idx 209: Modalité ASL, Région 1008 = WM Pédoncule cérébelleux moyen : Gauche
Feature idx 212: Modalité ASL, Région 1014 = WM Cingulaire antérieure : Gauche
Feature idx 229: Modalité FA, Région 6 = Temporale - autres gyri : Gauche
Feature idx 250: Modalité FA, Région 27 = Thalamus : Droit
Feature idx 251: Modalité FA, Région 28 = Pallidum : Gauche
Feature idx 261: Modalité FA, Région 1002 = WM Hippocampe et gyrus para-hippocampique : Gauche
Feature idx 264: Modalité FA, Région 1007 = WM Pédoncule cérébelleux moyen : Droit
Feature idx 272: Modalité FA, Région 1018 = WM Frontale moyen : Gauche
```

Figure 19 : Caractéristiques sélectionnées par le modèle d'arbre de décision (combinaison des 5 modalités)

Pour la plupart des modèles, on remarque que la majorité des régions anatomiques sont sélectionnées de manière bilatérale, c'est-à-dire à la fois pour l'hémisphère gauche et pour l'hémisphère droit. Cette observation est récurrente, quels que soient les modèles de machine learning utilisés, ce qui pourrait traduire une symétrie ou une redondance fonctionnelle entre les deux hémisphères pour certaines zones cérébrales.

En comparant les sélections de plusieurs modèles, plusieurs régions reviennent fréquemment, suggérant leur rôle potentiellement discriminant :



Par ailleurs, le nombre de caractéristiques retenues varie fortement selon l'algorithme utilisé. Ces sélections ont été réalisées à partir d'un jeu de données combinant les cinq types de cartes disponibles, soit un total de 280 caractéristiques.

- SVM linéaire : 19 caractéristiques sélectionnées, soit une sélection très parcimonieuse,
- SVM non linéaire : 200 caractéristiques, indiquant une sélection beaucoup plus large,
- Régression logistique : 28 caractéristiques retenues,
- Arbre de décision : 6 caractéristiques, soit la sélection la plus stricte,
- Random Forest : 106 caractéristiques sélectionnées, soit un compromis entre richesse et parcimonie.

Ces résultats montrent que certains modèles, comme le SVM non linéaire, tendent à capturer une plus grande variété de régions et de modalités, tandis que d'autres, comme l'arbre de décision ou le SVM linéaire, effectuent des sélections plus restreintes, potentiellement centrées sur les régions les plus discriminantes. La robustesse et l'interprétabilité des modèles peuvent ainsi varier selon le type de sélection effectuée.

8.4.2. Evaluation des performances

Les courbes ROC et les matrices de confusion reportées dans le **tableau 3**, correspondent aux meilleures performances obtenues par chacun des 5 algorithmes d'apprentissage supervisé considéré. Le tableau indique également pour chacun la combinaison de caractéristiques ayant permis d'obtenir ce résultat.




Tableau 3: Résumé des meilleures performances de prédiction pour chaque modèle, selon la meilleure combinaison de paramètres (choisie en fonction de l'AUC)

Les résultats mettent clairement en évidence l'impact positif de la multimodalité. Le modèle basé sur les forêts d'arbres décisionnels atteint des performances supérieures avec une AUC de 0.8053 et une exactitude de 0.79, lorsque les modalités CL, ASL et MD sont combinées. À l'inverse, deux modèles ont identifié une seule modalité comme configuration optimale (MD pour la régression logistique, et ASL pour l'arbre décisionnel).

Bien que les performances restent correctes dans ces cas (avec des AUC supérieures à 0.70), elles demeurent systématiquement inférieures à celles obtenues avec des approches multimodales, soulignant les limites informatives d'une modalité isolée face à la complexité du problème étudié. Cette observation est cohérente avec les analyses statistiques préalables (section 8.3), où la monomodalité ne permettait pas de réaliser de séparation significative entre les deux groupes.

Il convient aussi de remarquer que les résultats présentés dans le **tableau 3** montrent des performances sensiblement moins satisfaisantes pour les patients en état de non-éveil. En effet, les performances de prédiction pour le groupe non-éveil, dont les scores dans la matrice de confusion se situent entre 0.55 et 0.68, demeurent clairement en deçà de celles obtenues pour le groupe éveil, qui atteignent des valeurs nettement plus élevées, comprises entre 0.73 et 0.87. Cette disparité souligne une limitation importante des modèles testés : leur difficulté à identifier avec précision les états de non-éveil, malgré une classification globalement correcte. Ce déséquilibre de performance entre les deux groupes mérite une attention particulière, car il reflète à la fois la difficulté à repérer un état de conscience minimal et l'importance clinique d'un bon diagnostic.

Un tableau récapitulatif, présenté en annexe [\[Annexe 21\]](#), synthétise les deux meilleures et deux moins bonnes combinaisons identifiées pour chacun des modèles. Cette vue d'ensemble met en évidence l'intérêt de l'utilisation de multimodalités dans l'amélioration des performances diagnostiques par apprentissage automatique.

Par ailleurs, pour chaque combinaison de modalités et pour l'ensemble des modèles testés, le nombre de fois où chaque patient a été mal classé a été recensé [\[Annexe 22\]](#). Cela permet d'identifier les sujets les plus fréquemment associés à des erreurs de classification, et potentiellement de mieux comprendre les cas les plus difficiles à prédire. Cette analyse ne permet pas, à elle seule, d'expliquer les raisons des erreurs, mais elle fournit une base utile pour un examen plus approfondi, notamment par un neurologue. En effet, des facteurs comme la qualité des images, la présence d'artéfacts, ou des erreurs de segmentation pourraient expliquer certaines difficultés, mais cela nécessite une expertise clinique pour être confirmé. Dans notre cas, aucune cause visuelle évidente (artefact, segmentation incorrecte) n'a pu être identifiée à partir des images paramétriques. Cette étude met également en évidence une tendance claire (observable sur la **figure 20** ci-dessous): les patients appartenant au groupe non éveil sont plus fréquemment mal classés que ceux du groupe éveil, ce qui est en accord avec nos résultats précédents montrant une performance globale plus faible pour la classification de l'état de conscience dans le groupe non éveil.




Figure 20: Boxplots du nombre d'erreurs de classification par patient, selon les groupes "éveil" et "non-éveil".

9. DISCUSSION

Le jeu de données sur lequel ce projet est fondé comporte jusqu'à 280 variables par sujet, ce qui est considérable compte tenu du nombre limité de patients ($n = 52$). Un tel déséquilibre entre variables et observations constitue un obstacle majeur à l'application de méthodes d'apprentissage robustes, augmentant le risque de surapprentissage et rendant difficile l'identification de patterns réellement généralisables.

Parmi les variables sélectionnées par nos modèles, nous observons que lorsqu'une région cérébrale est identifiée comme pertinente, sa contrepartie dans l'hémisphère opposé l'est également très souvent. C'est notamment le cas pour les pédoncules cérébelleux moyens gauche et droit. Cette symétrie dans la sélection soulève la question de l'importance de la latéralisation dans l'analyse. Il serait intéressant d'évaluer si la prise en compte de régions bilatérales, plutôt que séparées par hémisphère, pourrait améliorer la performance des modèles. Concrètement, cela reviendrait à simplifier l'analyse sans perte d'information significative à condition que l'approche reste cohérente à travers l'ensemble des modalités utilisées.

Par ailleurs, les variables de captation du FDG sont rarement sélectionnées par les modèles, au profit de l'ASL. Cette préférence peut s'expliquer par la corrélation fréquente entre ces deux mesures : en effet, une zone du cerveau qui consomme plus de glucose (mesuré par FDG) a généralement aussi un débit sanguin plus élevé (mesuré par ASL). Ce lien, appelé couplage entre métabolisme et circulation sanguine, est attendu dans des tissus cérébraux peu endommagés.

Globalement, même si les modèles parviennent à prédire de manière satisfaisante l'état des patients appartenant au groupe "éveil", la classification des patients du groupe "non éveil" demeure nettement plus incertaine. Cette difficulté pourrait en partie s'expliquer par le traitement des patients NA, que nous avons intégrés au groupe "non éveil". Or, ces patients correspondent en réalité à des décès, ce qui pose un problème : bien qu'ils ne soient pas éveillés, leur trajectoire clinique est fondamentalement différente de celle des patients vivants mais non éveillés à 3 mois. En les regroupant sous la même étiquette, on introduit donc une hétérogénéité clinique dans la classe "non éveil". Le signal associé au non éveil réel peut ainsi être perturbé par les cas de décès, dont les profils d'imagerie peuvent différer. Cela pourrait expliquer une part de la baisse de performance observée sur cette classe. Cependant, le choix d'intégrer ces patients NA au groupe "non éveil" repose sur une contrainte méthodologique : leur exclusion aurait entraîné une réduction supplémentaire de la taille de la cohorte, déjà limitée, compromettant encore davantage la robustesse statistique des analyses. Cette limite a des implications importantes en pratique clinique, où la question cruciale est souvent de savoir si les soins doivent être poursuivis ou non. Une méthode fiable pour prédire l'éveil, même en l'absence de bonne prédiction du non-éveil, pourrait s'avérer utile. En effet, on pourrait envisager une stratégie consistant à maintenir les soins si le modèle prédit un non-éveil (afin d'éviter une décision trop hâtive), mais à envisager une réduction progressive de la sédation ou une adaptation des soins lorsque l'éveil est anticipé, facilitant ainsi une transition plus douce pour le patient.

Les meilleures performances de nos modèles peuvent être comparées à celles de l'étude multicentrique de Puybasset et al. [6], qui a utilisé des images de diffusion (FA et MD) pour prédire l'issue clinique à un an, avec une spécificité supérieure à 95 % pour les deux catégories de patients. Nos résultats sont moins élevés, ce qui peut s'expliquer par un objectif temporel différent : nous cherchons à prédire l'état de conscience à 3 mois, une période encore sujette à des évolutions neurologiques majeures, rendant le pronostic plus incertain. Il serait donc pertinent, dans des analyses futures, de réévaluer nos modèles en utilisant une issue à 1 an, plus stable et directement comparable à l'étude de référence.

De plus, l'étude dans laquelle s'inscrit ce projet comprenait une revue de l'état de l'art en deep learning appliqué à ce type de données. Cependant, les essais menés dans ce cadre se sont révélés peu concluants, principalement en raison de la taille réduite de la cohorte. Il est bien connu que les modèles de deep learning nécessitent de grandes quantités de données, notamment d'images médicales, pour atteindre de bonnes performances. Une piste prometteuse serait de relancer l'approche deep learning, non pas avec les images brutes, mais en utilisant comme entrée les vecteurs de caractéristiques extraits et sélectionnés par notre méthode actuelle. Cela permettrait d'exploiter la puissance du deep learning tout en limitant le risque de surapprentissage lié à la faible taille de l'échantillon.

Enfin, une autre perspective d'amélioration serait d'intégrer des données cliniques complémentaires, telles que l'âge, le sexe, les antécédents médicaux, ou d'autres variables contextuelles, afin d'enrichir le modèle et potentiellement améliorer sa capacité de prédiction.

10. CONCLUSION

La prise en charge des patients comateux repose en grande partie sur l'évaluation de leur état de conscience. Cependant, les examens cliniques traditionnels ne sont pas toujours fiables, car ils se basent sur les réponses observables du patient, qui peuvent être absentes même en présence d'une activité cérébrale résiduelle. De plus, il n'existe pas de lien direct entre l'étendue visible des lésions à l'imagerie et la capacité à récupérer un état d'éveil. Cette incertitude rend difficile le pronostic et justifie le développement d'outils plus objectifs, utilisant les données d'imagerie cérébrale pour estimer les chances de réveil. Le projet s'est ainsi donné pour objectif de prédire l'état d'éveil à trois mois chez les patients comateux, en exploitant les images multimodales IRM et TEP acquises peu après l'arrêt de la sédation.

La première phase du projet consiste en un travail de préparation des données a été nécessaire. Il a porté sur le prétraitement des différentes modalités d'imagerie (IRM anatomique, IRM de perfusion, IRM de diffusion et TEP au FDG), leur recalage dans un espace commun, un contrôle qualité, ainsi que la segmentation automatique des lésions. Des cartes de parcellisation anatomique ont ensuite été adaptées à chaque patient, en tenant compte de la présence de lésions. Cela a permis d'extraire, pour chaque région cérébrale, des indicateurs quantitatifs tels que la charge lésionnelle, le débit sanguin, l'activité métabolique et les paramètres de diffusion. L'ensemble de ce processus a été intégré dans un pipeline automatisé, assurant reproductibilité, traçabilité et homogénéité du traitement.

Plusieurs approches ont été explorées pour modéliser la relation entre ces biomarqueurs et l'évolution clinique. L'analyse statistique (tests multivariés et visualisation t-SNE) a permis de comparer les groupes de patients selon chaque modalité de manière isolée. Toutefois, ces analyses restent limitées pour une prédiction précise, notamment en raison de la variabilité inter-individuelle et du grand nombre de paramètres impliqués.

Pour dépasser ces limites, des modèles d'apprentissage automatique supervisé ont été mis en œuvre, parmi lesquels les machines à vecteurs de support (SVM), la régression logistique, les arbres de décision et les forêts aléatoires. Chaque modèle présente des avantages : les modèles linéaires sont simples et rapides, mais peu adaptés à des données complexes ; les modèles non linéaires sont plus performants, mais peuvent être sensibles au surapprentissage. Un protocole rigoureux, avec validation croisée et ajustement des paramètres, a été utilisé pour garantir une évaluation fiable des performances. Les performances des différents modèles ont été évaluées à l'aide d'indicateurs classiques tels que l'aire sous la courbe ROC (AUC), la précision, la sensibilité

et la spécificité. Le critère principal retenu pour comparer les modèles a été l'AUC moyenne obtenue en validation croisée.





Les résultats ont clairement montré que le modèle basé sur la forêt aléatoire, appliqué à la combinaison de trois modalités (charge lésionnelle, perfusion (ASL) et diffusivité moyenne (MD)) présentait les performances les plus élevées atteignant une AUC moyenne supérieure à 0,8.. Cette évaluation met en évidence un point essentiel : l'approche multimodale, qui exploite des informations complémentaires issues de différentes techniques d'imagerie, s'avère nettement plus efficace que les analyses reposant sur une seule modalité (AUC plafonnant à 0,72). Le projet a ainsi permis de démontrer de manière rigoureuse l'intérêt d'intégrer plusieurs sources d'imagerie pour améliorer la qualité des prédictions de l'éveil chez les patients comateux.

Ce travail a permis de poser les bases d'un outil d'aide à la décision, fondé sur l'intelligence artificielle, pour améliorer le pronostic chez les patients comateux. L'outil est fonctionnel, validé sur une cohorte de 52 patients, et présente des performances encourageantes. Il a montré de bonnes capacités à identifier les patients susceptibles de s'éveiller, mais reste moins performant pour prédire de façon fiable les cas de non-éveil. Cette limite est toutefois acceptable dans le contexte clinique visé, où il est prioritaire de repérer les patients ayant un potentiel de récupération. Plusieurs perspectives sont envisageables pour la suite: l'inclusion de nouveaux patients pour renforcer la robustesse du modèle, l'ajout de données cliniques ou neurophysiologiques comme l'EEG, ou encore la validation externe sur des cohortes indépendantes. À plus long terme, ce type d'approche pourrait contribuer à améliorer la prise en charge des troubles de la conscience en milieu de soins intensifs.

11. RÉFÉRENCES

- [1] Imagerie translationnelle et multimodale des corrélats neuronaux de la vigilance et de la conscience. (s. d.). Agence Nationale de la Recherche. <https://anr.fr/Projet-ANR-18-CE17-0012>
- [2] Kondziella D, et al; EAN Panel on Coma, Disorders of Consciousness. European Academy of Neurology guideline on the diagnosis of coma and other disorders of consciousness. *Eur J Neurol*. 2020 May;27(5):741-756. doi: 10.1111/ene.14151. Epub 2020 Feb 23. PMID: 32090418.
- [3] A. Comanducci, M. Boly, et al, Clinical and advanced neurophysiology in the prognostic and diagnostic evaluation of disorders of consciousness: review of an IFCN-endorsed expert group, *Clinical Neurophysiology*, Volume 131, Issue 11, 2020, Pages 2736-2765, ISSN 1388-2457, <https://doi.org/10.1016/j.clinph.2020.07.015>.
- [4] Edlow BL, Claassen J, Schiff ND, Greer DM. Recovery from disorders of consciousness: mechanisms, prognosis and emerging therapies. *Nat Rev Neurol*. 2021 Mar;17(3):135-156. doi: 10.1038/s41582-020-00428-x. Epub 2020 Dec 14. PMID: 33318675; PMCID: PMC7734616.
- [5] Amiri M, Fisher PM, et al; Multimodal prediction of residual consciousness in the intensive care unit: the CONNECT-ME study. *Brain*. 2023 Jan 5;146(1):50-64. doi: 10.1093/brain/awac335. PMID: 36097353; PMCID: PMC9825454.
- [6] Puybasset, L., Perlberg, V., Unrug, J., Cassereau, D., Galanaud, D., Torkomian, G., Battisti, V., Lefort, M., Velly, L., Degos, V., Citerio, G., Bayen, É., & Pelegrini-Issac, M. (2021). Prognostic value of global deep white matter DTI metrics for 1-year outcome prediction in ICU traumatic brain injury patients : an MRI-COMA and CENTER-TBI combined study. *Intensive Care Medicine*, 48(2), 201-212. <https://doi.org/10.1007/s00134-021-06583-z>
- [7] Lohmann P, Meißner AK, Kocher M, Bauer EK, Werner JM, Fink GR, Shah NJ, Langen KJ, Galldiks N. Feature-based PET/MRI radiomics in patients with brain tumors. *Neurooncol Adv*. 2021 Jan 23;2(Suppl 4):iv15-iv21. doi: 10.1093/noajnl/vdab118. PMID: 33521637; PMCID: PMC7829472.
- [8] Individual Adult Brain atlases – Brain development. (s. d.). http://brain-development.org/brain-atlases/adult-brain-atlases/individual-adult-brain-atlases/#LICENSE_AGREEMENT
- [9] Présentation de l'analyse MANOVA - Minitab. (s. d.). (C) Minitab, LLC. All Rights Reserved. 2025. <https://support.minitab.com/fr-fr/minitab/help-and-how-to/statistical-modeling/anova/supporting-topics/basics/understanding-manova/>
- [10] Besse, P. (s. d.). Analyse de variance multivariée — MANOVA. math.univ-toulouse. Consulté le 28 juillet 2025, à l'adresse <https://www.math.univ-toulouse.fr/~besse/Wikistat/pdf/st-m-modmixt5-manova.pdf>
- [11] Xu, L., Yang, Y., Guo, E. et al. Diagnostic evaluation of patients with disorders of consciousness with diffusion tensor imaging. *Chin Neurosurg J* 3, 17 (2017). <https://doi.org/10.1186/s41016-017-0079-2>

[12] Keijzer HM, Duering M, Pasternak O, Meijer FJA, Verhulst MMLH, Tonino BAR, Blans MJ, Hoedemaekers CWE, Klijn CJM, Hofmeijer J. Free water corrected diffusion tensor imaging discriminates between good and poor outcomes of comatose patients after cardiac arrest. *Eur Radiol.* 2023 Mar;33(3):2139-2148. doi: 10.1007/s00330-022-09245-w. Epub 2022 Nov 24. PMID: 36418623; PMCID: PMC9935650.

12. ANNEXES**Figure 1:** Chronologie d'inclusion des patients de l'étude**Figure 2a:** IRM T1**Figure 2b:** Superposition de la carte de parcellisation Hammers 83 régions et de l'IRM T1**Figure 2c:** Superposition de la carte de parcellisation Hammers WMGM 141 régions et de l'IRM T1**Figure 2:** Carte de parcellisation Hammers et Hammers WMGM

```
=====
Log started at 2025-07-21 17:05:23
=====

Available steps:
Preprocessing steps:
 00 - Create subfolders per subject in target directories
 01 - Orient and filter Pixyl segmentations
 02 - Applying thresholds (proba)
 03 - Applying thresholds (MS proba)
 04 - Masking FLAIR
 05 - Categorizing lesions
 06 - Processing manual segmentations
 07 - Reclassify all lesions as parenchymal edema (label 2)
 08 - Selecting and cleaning atlas
 09 - Hammers to crf
 10 - Calculating lesion load
 11 - Resampling ASL
 12 - Resampling FDG
 13 - PET and perfusion extraction
 14 - Diffusion computation and registration
 15 - Diffusion extraction
Analysis steps:
 16 - Analyzing lesion load
 17 - Analyzing lesion load per groups
 18 - PET and perfusion analyze
 19 - Diffusion analyze

What would you like to run?
1 - The entire pipeline
2 - Only the preprocessing steps
3 - Only the analysis steps
4 - A specific step
Your choice (1-4): 4
[USER INPUT] Mode selected: 4
```

Figure 3: Lancement du programme générale réalisant le prétraitement et l'extraction de données




Figure 4: Exemple d'un sujet ayant une carte de parcellisation mal segmentée




Figure 5: Exemple d'une IRM de perfusion ayant des données manquantes




Figure 6: Exemple d'une IRM de perfusion ayant un artefact de bande





Figure 7: Boxplots des volumes (en voxels) de chaque région au sein de la cohorte







Figure 10: Evolution des charges lésionnelles en fonction des régions chez tous les patients






Figure 12: Boxplots des charges lésionnelles selon le type de lésion (hématome: bleu, œdème: rose, lésion totale: vert), en distinguant les deux groupes selon l'état d'éveil




Figure 13: Distribution du nombre de régions affectées par une lésion selon l'état d'éveil, en distinguant les hématomes (bleu) et les œdèmes (rose)




Figure 14: Boxplots des métriques extraites des données d'IRM de perfusion pour l'ensemble des régions: médiane (haut gauche), maximum (haut droit), écart-type (bas gauche) et pic (bas droit), en distinguant les groupes *éveil* (bleu) et *non éveil* (orange)




Figure 15: Boxplots des métriques extraites des données TEP-FDG pour l'ensemble des régions: médiane (haut gauche), maximum (haut droit), écart-type (bas gauche) et pic (bas droit), en distinguant les groupes *éveil* (bleu) et *non éveil* (orange)



Figure 16: Boxplots des métriques extraites des cartes de diffusion AD (haut) et RD (bas) pour l'ensemble des régions, en distinguant les groupes *éveil* (bleu) et *non éveil* (orange)

Multivariate linear model						
Groupe	Value	Num DF	Den DF	F	Value	Pr > F
Wilks' lambda	0.0487	56.0000	6.0000	2.8938	0.1778	
Pillai's trace	0.9513	56.0000	6.0000	2.8938	0.1778	
Hotelling-Lawley trace	19.5423	56.0000	6.0000	2.8938	0.1778	
Roy's greatest root	19.5423	56.0000	6.0000	2.8938	0.1778	

Charge lésionnelle

Multivariate linear model						
Groupe	Value	Num DF	Den DF	F	Value	Pr > F
Wilks' lambda	0.0022	56.0000	1.0000	8.2643	0.2707	
Pillai's trace	0.9978	56.0000	1.0000	8.2643	0.2707	
Hotelling-Lawley trace	462.8024	56.0000	0.5000	4.1322	0.5388	
Roy's greatest root	462.8024	56.0000	1.0000	8.2643	0.2707	

ASL

Multivariate linear model						
Groupe	Value	Num DF	Den DF	F	Value	Pr > F
Wilks' lambda	0.2020	56.0000	13.0000	0.9174	0.6137	
Pillai's trace	0.7980	56.0000	13.0000	0.9174	0.6137	
Hotelling-Lawley trace	3.9517	56.0000	13.0000	0.9174	0.6137	
Roy's greatest root	3.9517	56.0000	13.0000	0.9174	0.6137	

FDG

Multivariate linear model						
Groupe	Value	Num DF	Den DF	F	Value	Pr > F
Wilks' lambda	0.1925	56.0000	14.0000	1.0484	0.4809	
Pillai's trace	0.8075	56.0000	14.0000	1.0484	0.4809	
Hotelling-Lawley trace	4.1937	56.0000	14.0000	1.0484	0.4809	
Roy's greatest root	4.1937	56.0000	14.0000	1.0484	0.4809	

EA

Multivariate linear model						
Groupe	Value	Num DF	Den DF	F	Value	Pr > F
Wilks' lambda	0.3434	56.0000	14.0000	0.4781	0.9736	
Pillai's trace	0.6566	56.0000	14.0000	0.4781	0.9736	
Hotelling-Lawley trace	1.9123	56.0000	14.0000	0.4781	0.9736	
Roy's greatest root	1.9123	56.0000	14.0000	0.4781	0.9736	

MD

Figure 17: Tests MANOVA pour chaque modalité/valeur a étudiée




Figure 18: Représentation t-SNE en 2D et 3D des mesures régionales pour modalité IRM de perfusion - ASL




Figure 19: Représentation t-SNE en 2D et 3D des mesures régionales pour la modalité TEP-FDG




Figure 20: Représentation t-SNE en 2D et 3D des mesures régionales pour la modalité IRM de diffusion - FA

		SVML																		
Combinaison Nb features AUC	LL, FDG, MD					ASL, FDG					FDG					FDG, FA				
	17					9					5					13				
	0.739					0.717					0.462					0.461				
Matrice de confusion	[[0.55 0.45] [0.27 0.73]]					[[0.59 0.41] [0.23 0.77]]					[[0 1] [0 1]]					[[0 1] [0 1]]				
	precision	recall	f1-score	support		precision	recall	f1-score	support		precision	recall	f1-score	support		precision	recall	f1-score	support	
Rapport de classification	0	0.6	0.55	0.57	20	0	0.65	0.59	0.62	22	0	0	0	0	22	0	0	0	0	22
	1	0.69	0.73	0.71	30	1	0.72	0.77	0.74	30	1	0.58	1	0.73	30	1	0.58	1	0.73	30
	accuracy				52	accuracy				52	accuracy				52	accuracy				52
	macro avg	0.64	0.64	0.64	52	macro avg	0.68	0.68	0.68	52	macro avg	0.29	0.5	0.37	52	macro avg	0.29	0.5	0.37	52
	weighted avg	0.65	0.65	0.65	52	weighted avg	0.69	0.69	0.69	52	weighted avg	0.33	0.58	0.42	52	weighted avg	0.33	0.58	0.42	52

		SVMNL																		
Combinaison Nb features AUC	LL, ASL					ASL, MD					ASL, FDG					ASL				
	15					100					50					10				
	0.747					0.707					0.341					0.33				
Matrice de confusion	[[0.64 0.36] [0.27 0.73]]					[[0.55 0.45] [0.23 0.77]]					[[0.45 0.55] [0.40 0.60]]					[[0.45 0.55] [0.40 0.60]]				
	precision	recall	f1-score	support		precision	recall	f1-score	support		precision	recall	f1-score	support		precision	recall	f1-score	support	
Rapport de classification	0	0.64	0.64	0.64	22	0	0.63	0.55	0.59	22	0	0.45	0.45	0.45	22	0	0.45	0.45	0.45	22
	1	0.73	0.73	0.73	30	1	0.7	0.77	0.73	30	1	0.6	0.6	0.6	30	1	0.6	0.6	0.6	30
	accuracy				52	accuracy				52	accuracy				52	accuracy				52
	macro avg	0.68	0.68	0.68	52	macro avg	0.66	0.66	0.66	52	macro avg	0.53	0.53	0.53	52	macro avg	0.53	0.53	0.53	52
	weighted avg	0.69	0.69	0.69	52	weighted avg	0.67	0.67	0.67	52	weighted avg	0.54	0.54	0.54	52	weighted avg	0.54	0.54	0.54	52

		LR																		
Combinaison Nb features AUC	MD					ASL					FDG, FA					FA				
	28					24					33					20				
	0.721					0.719					0.565					0.515				
Matrice de confusion	[[0.59 0.41] [0.17 0.83]]					[[0.36 0.64] [0.27 0.73]]					[[0.50 0.50] [0.43 0.57]]					[[0.50 0.50] [0.40 0.60]]				
	precision	recall	f1-score	support		precision	recall	f1-score	support		precision	recall	f1-score	support		precision	recall	f1-score	support	
Rapport de classification	0	0.72	0.59	0.65	22	0	0.5	0.36	0.42	22	0	0.46	0.5	0.48	22	0	0.48	0.5	0.49	22
	1	0.74	0.83	0.78	30	1	0.61	0.73	0.67	30	1	0.61	0.57	0.59	30	1	0.62	0.6	0.61	30
	accuracy				52	accuracy				52	accuracy				52	accuracy				52
	macro avg	0.73	0.71	0.72	52	macro avg	0.56	0.55	0.54	52	macro avg	0.53	0.53	0.53	52	macro avg	0.55	0.55	0.55	52
	weighted avg	0.73	0.73	0.73	52	weighted avg	0.56	0.58	0.56	52	weighted avg	0.54	0.54	0.54	52	weighted avg	0.56	0.56	0.56	52

		DT																		
Combinaison Nb features AUC	ASL					MD					FDG, FA, MD					FA				
	6					7					7					8				
	0.703					0.688					0.467					0.404				
Matrice de confusion	[[0.68 0.32] [0.27 0.73]]					[[0.59 0.41] [0.23 0.77]]					[[0.45 0.55] [0.47 0.53]]					[[0.32 0.68] [0.47 0.53]]				
	precision	recall	f1-score	support		precision	recall	f1-score	support		precision	recall	f1-score	support		precision	recall	f1-score	support	
Rapport de classification	0	0.35	0.68	0.67	22	0	0.65	0.59	0.62	22	0	0.42	0.45	0.43	22	0	0.33	0.32	0.33	22
	1	0.76	0.73	0.75	30	1	0.72	0.77	0.74	30	1	0.57	0.53	0.55	30	1	0.52	0.53	0.52	30
	accuracy				52	accuracy				52	accuracy				52	accuracy				52
	macro avg	0.71	0.71	0.71	52	macro avg	0.68	0.68	0.68	52	macro avg	0.49	0.49	0.49	52	macro avg	0.42	0.43	0.43	52
	weighted avg	0.71	0.71	0.71	52	weighted avg	0.69	0.69	0.69	52	weighted avg	0.51	0.5	0.5	52	weighted avg	0.44	0.44	0.44	52

		RF																		
Combinaison Nb features AUC	LL, ASL, MD					LL, ASL, FDG					FA					FDG, FA				
	64					62					22					48				
	0.805					0.789					0.491					0.473				
Matrice de confusion	[[0.68 0.32] [0.13 0.87]]					[[0.68 0.32] [0.13 0.87]]					[[0.36 0.64] [0.33 0.67]]					[[0.36 0.64] [0.33 0.67]]				
	precision	recall	f1-score	support		precision	recall	f1-score	support		precision	recall	f1-score	support		precision	recall	f1-score	support	
Rapport de classification	0	0.79	0.68	0.73	22	0	0.79	0.68	0.73	22	0	0.44	0.36	0.4	22	0	0.44	0.36	0.4	22
	1	0.79	0.87	0.83	30	1	0.79	0.87	0.83	30	1	0.59	0.67	0.62	30	1	0.59	0.67	0.62	30
	accuracy				52	accuracy				52	accuracy				52	accuracy				52
	macro avg	0.79	0.77	0.78	52	macro avg	0.79	0.77	0.78	52	macro avg	0.52	0.52	0.51	52	macro avg	0.52	0.52	0.51	52
	weighted avg	0.79	0.79	0.79	52	weighted avg	0.79	0.79	0.79	52	weighted avg	0.53	0.54	0.53	52	weighted avg	0.53	0.54	0.53	52

Meilleure performance
Deuxième meilleure performance
Deuxième pire performance
Pire performance

Figure 21: Tableau synthétique des deux meilleures et deux moins bonnes combinaisons de modalités pour chaque modèle

Sujet	Total mal classés	Pourcentage d'erreurs
GY10778	5	3,23
DO10898	7	4,52
VINTH07401	9	5,81
EA11945	13	8,39
SV11900	13	8,39
RJ11136	15	9,68
AJ10477	16	10,32
SK11073	19	12,26
SO11859	21	13,55
PAJO07564	22	14,19
AJ10923	26	16,77
LAYCH07370	28	18,06
PICGA08615	28	18,06
MHO9586	29	18,71
FT09679	34	21,94
PERPA07438	34	21,94
BS10780	35	22,58
NN10771	38	24,52
RD11934	43	27,74
AM12174	47	30,32
ELABA07301	47	30,32
PA11557	47	30,32
EM10518	50	32,26
GM12051	52	33,55
BENCH07535	53	34,19
NESKA08577	54	34,84
RS10191	54	34,84
VILMA08560	55	35,48
HM11036	57	36,77
SB11414	57	36,77
GAJUL07407	58	37,42
GK11660	63	40,65
VS10506	63	40,65
DELPH07541	64	41,29
GY10986	67	43,23
BT10021	73	47,1
AYNSI07470	76	49,03
PL09870	80	51,61
GAYFR07495	85	54,84
FELNO07581	87	56,13
EM10512	90	58,06
VG11102	90	58,06
DURMO07595	96	61,94
LAIGI07087	98	63,23
THOTH08365	101	65,16
LX11720	106	68,39
BM11029	111	71,61
PM10845	111	71,61
CM10250	117	75,48
RS10272	126	81,29
AK10902	137	88,39
MP11963	142	91,61

NON EVEIL
EVEIL

Figure 22: Récapitulatif du nombre d'erreurs de classification par patient, selon les modèles et les combinaisons de modalités.

	4^{ÈME} PAGE DE COUVERTURE	Date du stage du 03/03/2025 au 03/09/2025
	Stage d'exécution ☐ Stage élève – ingénieur ☐ Stage année de césure : 12 mois ☐ 1er semestre ☐ 2ème semestre ☐ Stage projet de fin d'études ☒	

NOM et PRENOM du stagiaire: JUMELLE Capucine

Spécialité: ☐ CGP ☒ ETI

13. RÉSUMÉ

Ce stage de fin d'études s'inscrit dans le cadre du projet ANR IMAGINA, qui vise à améliorer le pronostic des patients comateux en phase aiguë à l'aide de l'imagerie multimodale. L'objectif principal de ce travail est de développer un modèle de prédiction de l'éveil à trois mois, en s'appuyant sur des biomarqueurs extraits d'images IRM et TEP réalisées peu après l'arrêt de la sédation. Ce modèle s'inscrit dans une démarche de médecine personnalisée, destinée à appuyer les décisions cliniques dans le contexte des troubles de la conscience.

Les données utilisées proviennent d'une cohorte de 71 patients répartis entre les essais cliniques ETIC et IMAGINA. Les modalités d'imagerie étudiées incluent : IRM anatomique (T1, FLAIR), IRM de perfusion (ASL), IRM de diffusion (DWI), et TEP au [¹⁸F]FDG. Un pipeline de traitement complet a été développé en Python pour automatiser les étapes de prétraitement, de segmentation des lésions, de parcellisation anatomique, et d'extraction de caractéristiques quantitatives régionales (intensité moyenne, charge lésionnelle, indices de diffusion, etc.). L'ensemble des cartes a été aligné dans l'espace IRM T1 pour garantir une comparaison intermodale fiable.

L'analyse statistique (MANOVA) et la visualisation des répartitions des données (t-SNE) n'ont pas mis en évidence de différences statistiquement significatives entre les groupes « éveil » et « non éveil » pour les modalités prises séparément. Des modèles de classification supervisée (SVM, régression logistique, arbre de décision, random forest) ont été entraînés et évalués via une validation croisée à 5 plis. Les performances les plus prometteuses ont été obtenues avec les approches multimodales combinant IRM de diffusion, IRM de perfusion et IRM anatomique (charge lésionnelle), atteignant des AUC supérieurs à 0,80 avec le modèle random forest. À l'inverse, les approches unimodales, telles que la diffusion seule, restent limitées et plafonnent à un AUC de 0,72 en régression logistique.

Ce travail montre qu'une intégration rigoureuse de données multimodales améliore la prédiction de l'éveil par rapport à l'analyse unimodale. Les conclusions ouvrent des perspectives cliniques concrètes, notamment en tant qu'outil d'aide à la décision dans les unités de réanimation. À plus long terme, l'approche pourrait être généralisée à d'autres types de troubles de la conscience ou élargie à des modèles prédictifs plus avancés, incluant des données longitudinales ou d'autres modalités fonctionnelles (EEG, IRMf).